

Введение в машинное обучение


Практическая работа № 1

ФИО преподавателя:

e-mail:

Парная линейная регрессия и метод наименьших квадратов

Математическая зависимость величин




НАПРАВЛЕНИЕ ЗАВИСИМОСТИ:

- Положительная
- Отрицательная

СИЛА ЗАВИСИМОСТИ:



- Отсутствует
- Слабая
- Средняя
- Сильная
- Абсолютная

Наличие математической зависимости / корреляции **НЕ ОЗНАЧАЕТ** наличия **ПРИЧИННО-СЛЕДСТВЕННОЙ** взаимосвязи между переменными



$$\tau_{y,x} = -1$$


$$-1 < \tau_{y,x} < 0$$



ЗАДАНИЕ:


**ОПРЕДЕЛИТЬ
НАПРАВЛЕНИЕ
И СИЛУ
ЗАВИСИМОСТИ
ПЕРЕМЕННЫХ**

МНОЖЕСТВО КОРРЕЛЯЦИОННЫХ ПОЛЕЙ



Как можно количественно выразить математическую зависимость 2-х величин ?

Корреляция веса и роста по выборке в 500 человек



КОВАРИАЦИЯ

КОРРЕЛЯЦИЯ

КОВАРИАЦИЯ – это степень согласованности отклонений двух переменных

$$\text{cov}(x, y) = \Sigma[(\mathbf{X} - \text{среднее}\mathbf{X})(\mathbf{Y} - \text{среднее}\mathbf{Y})]$$

Смысл: если 1 варианта отклоняется от средней, можно ожидать, что 2-я отклонится в ту же сторону

КОРРЕЛЯЦИЯ – это ковариация стандартизованных переменных

$$r = \text{cov}(x, y) / \text{SD}_{xy}$$

Смысл: отношение наблюдаемой ковариации двух стандартизованных переменных к максимально возможной ковариации

Ковариация

- Важной характеристикой совместного распределения двух случайных величин является ковариация (или корреляционный момент).
- Ковариация определяется как математическое ожидание произведения отклонений случайных величин:
$$\text{cov}_{XY} = \mathbf{M}[(X - \mathbf{M}(X))(Y - \mathbf{M}(Y))] = \mathbf{M}(XY) - \mathbf{M}(X)\mathbf{M}(Y)$$
- Ковариация двух независимых случайных величин X и Y равна нулю
- Ковариация имеет размерность, равную произведению размерности случайных величин, то есть величина ковариации зависит от единиц измерения независимых величин.
 - Данная особенность ковариации затрудняет её использование в целях корреляционного анализа.

КОРРЕЛЯЦИЯ

КОРРЕЛЯЦИЯ – это двумерное измерение силы и направления математической взаимосвязи между двумя переменными

-1




0

+1

абсолютная
негативная
линейная связь

случайная связь

абсолютная
положительная
линейная связь



КОЭФФИЦИЕНТЫ КОРРЕЛЯЦИИ

*Единственный
параметрический критерий*

	Непрерывные	Порядковые	Дихотомические
Непрерывные	Pearson's r Spearman's rho Kendall's tau	Spearman's rho Kendall's tau Polyserial correlation	Polyserial correlation Point-biserial correlation (истинная дихотомия) Biserial correlation (ложная дихотомия)
Порядковые	Spearman's rho Kendall's tau Polyserial correlation	Spearman's rho Kendall's tau Polychoric correlation	Rank biserial correlation
Дихотомические	Polyserial correlation Point-biserial correlation (истинная дихотомия) Biserial correlation (ложная дихотомия)	Rank biserial correlation	Polychoric correlation (tetrachoric correlation) phi

ЛИНЕЙНЫЙ КОЭФФИЦИЕНТ КОРРЕЛЯЦИИ

- Для устранения недостатка ковариации был введён линейный коэффициент корреляции (или коэффициент корреляции Пирсона).

$$r_{XY} = \frac{\text{cov}_{XY}}{\sigma_X \sigma_Y} = \frac{\sum (X - \bar{X})(Y - \bar{Y})}{\sqrt{\sum (X - \bar{X})^2 \sum (Y - \bar{Y})^2}}. \quad \bar{X} = \frac{1}{n} \sum_{t=1}^n X_t, \quad \bar{Y} = \frac{1}{n} \sum_{t=1}^n Y_t$$

- Коэффициент корреляции изменяется в пределах от -1 до +1.

Пример расчета коэффициента корреляции Пирсона

N	Содержание тестостерона в крови, нг/дл (X)	Процент мышечной массы, % (Y)
1.	951	83
2.	874	76
3.	957	84
4.	1084	89
5.	903	79

1 ЭТАП. Расчет суммы значений переменных X и Y:

$$\Sigma(X) = 951 + 874 + 957 + 1084 + 903 = 4769$$

$$\Sigma(Y) = 83 + 76 + 84 + 89 + 79 = 441$$

Пример расчета коэффициента корреляции Пирсона

N	Содержание тестостерона в крови, нг/дл (X)	Процент мышечной массы, % (Y)
1.	951	83
2.	874	76
3.	957	84
4.	1084	89
5.	903	79

2 ЭТАП. Расчет средних арифметических для X и Y:

$$M_x = \Sigma(X) / n = 4769 / 5 = 953.8$$

$$M_y = \Sigma(Y) / n = 441 / 5 = 82.2$$

Пример расчета коэффициента корреляции Пирсона

N	Содержание тестостерона в крови, нг/дл (X)	Процент мышечной массы, % (Y)	Отклонение содержания тестостерона от среднего значения (d_x)	Отклонение % мышечной массы от среднего значения (d_y)
1.	951	83	-2.8	0.8
2.	874	76	-79.8	-6.2
3.	957	84	3.2	1.8
4.	1084	89	130.2	6.8
5.	903	79	-50.8	-3.2

3 ЭТАП. Расчет для каждого значения сопоставляемых показателей величину отклонения от среднего арифметического

$$dx = X - Mx$$

$$dy = Y - My$$

Пример расчета коэффициента корреляции Пирсона

N	Содержание тестостерона в крови, нг/дл (X)	Процент мышечной массы, % (Y)	Отклонение содержания тестостерона от среднего значения (d_x)	Отклонение % мышечной массы от среднего значения (d_y)	d_x^2	d_y^2
1.	951	83	-2.8	0.8	7.84	0.64
2.	874	76	-79.8	-6.2	6368.04	38.44
3.	957	84	3.2	1.8	10.24	3.24
4.	1084	89	130.2	6.8	16952,04	46.24
5.	903	79	-50.8	-3.2	2580,64	10.24

4 ЭТАП. Возвести в квадрат каждое значение отклонения dx и dy

Пример расчета коэффициента корреляции Пирсона

N	Содержа ние тестосте рона в крови, нг/дл (X)	Процент мышечн ой массы, % (Y)	Отклоне ние содержа ния тестосте рона от среднего значени я (d_x)	Отклоне ние % мышечн ой массы от среднего значени я (d_y)	d_x^2	d_y^2	$d_x \times d_y$
1.	951	83	-2.8	0.8	7.84	0.64	-2.24
2.	874	76	-79.8	-6.2	6368.04	38.44	494.76
3.	957	84	3.2	1.8	10.24	3.24	5.76
4.	1084	89	130.2	6.8	16952,04	46.24	885.36
5.	903	79	-50.8	-3.2	2580,64	10.24	162.56

**5 ЭТАП. Расчет для каждой пары анализируемых значений
произведение отклонений $d_x \times d_y$:**

Пример расчета коэффициента корреляции Пирсона

6 ЭТАП. Расчет значения суммы квадратов отклонений

$$\Sigma(d_x^2) \text{ и } \Sigma(d_y^2)$$

$$\Sigma(d_x^2) = 25918.8$$

$$\Sigma(d_y^2) = 98.8$$

7 ЭТАП. Расчет значения суммы произведений отклонений

$$\Sigma(d_x \times d_y)$$

$$\Sigma(d_x \times d_y) = 1546.2$$

8 ЭТАП. Расчет значения коэффициента корреляции Пирсона

r_{xy}

$$r_{xy} = \frac{\Sigma(d_x \times d_y)}{\sqrt{(\Sigma d_x^2 \times \Sigma d_y^2)}} = \frac{1546.2}{\sqrt{(25918.8 \times 98.8)}} = 0.966$$

Пример расчета коэффициента корреляции Пирсона

9 ЭТАП. Оценка достоверности результата – расчет t-критерия

$$t_r = \frac{r_{xy} \sqrt{n - 2}}{\sqrt{1 - r_{xy}^2}} = \frac{0.97 \sqrt{5 - 2}}{\sqrt{1 - 0.97^2}} = 7.0$$

Критическое значение t-критерия можно найти по специальной статистической таблице

УСЛОВИЯ ПРИМЕНЕНИЯ КОРРЕЛЯЦИИ ПИРСОНА

ASSUMPTIONS / УСЛОВИЯ ПРИМЕНЕНИЯ

КАК ПРОВЕРИТЬ?

1. Сравниваем 2 выборки

см. характеристики собранных данных

2. Выборки д.б. независимыми

см. характеристики собранных данных

3. Количественный непрерывный тип данных в каждой из сравниваемых выборок

см. тип данных

4. Нормальное распределение изучаемого признака в каждой из выборок

Test Shapiro-Wilk / Kolmogorov-Smirnov

5. Гомоскедастичность - предполагается, что дисперсия ошибки остается той же самой в любой точке на протяжении всей линейной связи (иначе коэффициент корреляции будет завышаться или, наоборот, занижаться)

обычно не проверяется

КОЭФФИЦИЕНТ КОРРЕЛЯЦИИ ПИРСОНА

Значение коэффициента корреляции r	Интерпретация
$0 < r \leq 0,2$	Очень слабая корреляция
$0,2 < r \leq 0,5$	Слабая корреляция
$0,5 < r \leq 0,7$	Средняя корреляция
$0,7 < r \leq 0,9$	Сильная корреляция
$0,9 < r \leq 1$	Очень сильная корреляция

**Корреляция является симметричной,
поэтому она не может говорить о направлении
каузальной связи**

Коэффициент детерминации R^2

R^2 - коэффициент детерминации - доля дисперсии переменной X, объясняемая вариабельностью переменной Y

$$r_{xy} = 0,5$$

$$R^2 = 0,25$$

Таким образом, вариабельность переменной X объясняет 25% вариабельности переменной Y

УСЛОВИЯ ПРИМЕНЕНИЯ

КОЭФФИЦИЕНТА РАНГОВОЙ КОРРЕЛЯЦИИ СПИРМЕНА, КОЭФФИЦИЕНТА КОРРЕЛЯЦИИ КЕНДАЛЛА (τ)

ASSUMPTIONS / УСЛОВИЯ ПРИМЕНЕНИЯ

КАК ПРОВЕРИТЬ?


1. Сравниваем 2 выборки	см. характеристики собранных данных
2. Выборки д.б. независимыми	см. характеристики собранных данных
3. <u>Количественный непрерывный / порядковый</u> тип данных в каждой из сравниваемых выборок	см. тип данных
4. <u>Нормальное / скошенное</u> <u>распределение</u> изучаемого признака	<u>можно не проверять</u>

ОСНОВНОЙ НЕДОСТАТОК КОЭФФИЦИЕНТА КОРРЕЛЯЦИИ

Коэффициент корреляции демонстрирует

- А) направление взаимосвязи переменных
- Б) силу взаимосвязи переменных


НО коэффициент корреляции бесполезен, если мы хотим ПРЕДСКАЗАТЬ значение переменной X по значению переменной Y



РЕГРЕССИОННЫЙ АНАЛИЗ


Ограничения корреляции

- Применение возможно при наличии достаточного количества наблюдений для изучения.
 - На практике считается, что число наблюдений должно не менее чем в 5-6 раз превышать число факторов.
- Коэффициент корреляции отражает «зашумлённость» линейной зависимости (верхняя строка)
- Коэффициент корреляции не описывает наклон линейной зависимости (средняя строка)
- Коэффициент корреляции совсем не подходит для описания сложных, нелинейных зависимостей (нижняя строка).
- Для распределения, показанного в центре рисунка, коэффициент корреляции не определен, так как дисперсия у равна нулю.



КОРРЕЛЯЦИЯ VS. РЕГРЕССИЯ

Корреляция веса и роста по выборке в 500 человек



МЕЖДУ ПЕРЕМЕННЫМИ ЕСТЬ ЗАВИСИМОСТЬ?

КОРРЕЛЯЦИОННЫЙ АНАЛИЗ – демонстрирует лишь направление взаимосвязи переменных и силу взаимосвязи переменных

ИССЛЕДОВАТЕЛЯ МОГУТ ДОПОЛНИТЕЛЬНО ИНТЕРЕСОВАТЬ ВОПРОСЫ:

1) как сильно влияет на зависимую (1) переменную

А) другая (1) независимая переменная?

Б) одновременно 2 и > независимых переменных?

2) какие именно переменные влияют на зависимую переменную (отсеять из набора переменных «лишние»)?

3) какие именно переменные влияют одновременно на 2 и более зависимых переменных из набора?

4) можно ли по значениям одной (нескольких) переменных ПРЕДСКАЗАТЬ значение другой (других) переменных

Виды зависимостей между переменными

1. Функциональные: $Y = f(X)$.

Имеют место при исследовании связей между неслучайными переменными.

2. Статистические: изменение одной из величин влечет изменение закона распределения другой (доход – потребление, цена – спрос и т.д.).

Виды статистических зависимостей

а) Корреляционные: при изменении одной из величин изменяется среднее значение другой (связь между переменными не носит направленного характера)
 $M[Y/X = x] = M_x[Y] = \varphi(x), M[X/Y = y] = M_y[X] = \psi(y),$
где $M[Y/X = x]$ – м. о. случайной величины Y ,
вычисленное при условии, что случайная величина X
приняла значение x , $\varphi(x) \neq \text{const}, \psi(y) \neq \text{const}.$

б) Регрессионные: односторонняя зависимость среднего значения случайной величины Y от одной X или нескольких $X_1, \dots, X_m$ случайных величин.

РЕГРЕССИЯ: ОСНОВНАЯ ИДЕЯ

$$Y = f(X)$$



Зависимость между переменными может быть выражена *УРАВНЕНИЕМ*




ОСНОВНАЯ ИДЕЯ РЕГРЕССИОННОГО АНАЛИЗА:

*математически рассчитать параметры
УРАВНЕНИЯ РЕГРЕССИИ*

(с какой силой / в каком направлении переменные влияют на зависимую переменную)


РЕГРЕССИЯ: ОСНОВНАЯ ПРОБЛЕМА



нелинейная зависимость

**ЛИНЕЙНЫЙ
РЕГРЕССИОННЫЙ АНАЛИЗ**

**НЕЛИНЕЙНЫЙ
РЕГРЕССИОННЫЙ АНАЛИЗ**



линейная зависимость


КАКАЯ ФОРМА ЗАВИСИМОСТИ ОДНОЙ ПЕРЕМЕННОЙ ОТ ДРУГОЙ ПЕРЕМЕННОЙ?

КАКАЯ ФОРМА ЗАВИСИМОСТЬ ОДНОЙ ПЕРЕМЕННЫХ ОТ НЕСКОЛЬКИХ ПЕРЕМЕННЫХ?

ВЫБОР МОДЕЛИ РЕГРЕССИОННОГО АНАЛИЗА

ЗАВИСИМАЯ ПЕРЕМЕННАЯ


РЕГРЕССИЯ



+++ другие
методы
регрессионного
анализа
(напр.,
регрессия
Пуассона...)

Пример:

Регрессионная зависимость



Что такое регрессионный анализ?

- Регрессионный анализ представляет собой анализ форм связи, устанавливающих количественные соотношения между случайными величинами изучаемого случайного процесса.

Определение регрессии

Регрессия – функциональная зависимость между объясняющими переменными и условным математическим ожиданием (средним значением) зависимой переменной, которая строится с целью прогнозирования этого среднего значения при фиксированных значениях объясняющих переменных.

Логистическая регрессия: определение

- Л.Р. или логит-модель (англ. logit model) — это статистическая модель, используемая для прогнозирования вероятности возникновения некоторого события путём его сравнения с логистической кривой. Эта регрессия выдаёт ответ в виде вероятности бинарного события (1 или 0).
- Применяется для прогнозирования вероятности возникновения некоторого события по значениям множества признаков.
 - вводится так называемая зависимая переменная $y \in \{0, 1\}$
 - множество независимых переменных (также называемых признаками, предикторами или регрессорами) — $x_1, x_2, \dots, x_n \in \mathbb{R}$, на основе значений которых требуется вычислить вероятность принятия того или иного значения зависимой переменной
 - для простоты записи вводится фиктивный признак $x_0 = 1$

Логистическая регрессия: описание модели

- Делается предположение о том, что вероятность наступления события $y = 1$ равна


$$\mathbb{P}\{y = 1 \mid x\} = f(z), \quad z = \theta^T x = \theta_0 + \theta_1 x_1 + \dots + \theta_n x_n$$

- x – вектор-столбец значений независимых переменных $1, x_1, x_2, \dots, x_n$
- θ – вектор-столбец параметров (коэффициентов регрессии)
- $f(z)$ – логистическая функция (иногда также называемая сигмоидом или логит-функцией)

- Вероятность наступления события $y = 0$ равна

- Функция $\mathbb{P}\{y = 0 \mid x\} = 1 - f(z) = 1 - f(\theta^T x)$.

$$\mathbb{P}\{y \mid x\} = f(\theta^T x)^y (1 - f(\theta^T x))^{1-y}, \quad y \in \{0, 1\}.$$



$$f(x) = \frac{1}{1 + e^{-x}}$$

Логистическая регрессия: подбор параметров

- Для подбора параметров $\theta_0, \dots, \theta_n$ необходимо составить обучающую выборку, состоящую из наборов значений независимых переменных и соответствующих им значений зависимой переменной y .
$$\hat{\theta} = \operatorname{argmax}_{\theta} L(\theta) = \operatorname{argmax}_{\theta} \prod_{i=1}^m \mathbb{P}\{y = y^{(i)} \mid x = x^{(i)}\}.$$
 - Формально, это множество пар $(x^{(1)}, y^{(1)}), \dots, (x^{(m)}, y^{(m)})$, где $x^{(i)} \in \mathbb{R}^n$ и $y^{(i)} \in \{0, 1\}$. Каждая такая пара называется обучающим примером.
 - Обычно используется метод максимального правдоподобия, согласно которому

Подбор параметров: градиентный спуск

- Максимизация функции правдоподобия эквивалентна максимизации её логарифма:

$$\ln L(\theta) = \sum_{i=1}^m \log \mathbb{P}\{y = y^{(i)} \mid x = x^{(i)}\} = \sum_{i=1}^m y^{(i)} \ln f(\theta^T x^{(i)}) + (1 - y^{(i)}) \ln(1 - f(\theta^T x^{(i)}))$$

- Для максимизации этой функции может быть применён, например, метод градиентного спуска. Он заключается в выполнении следующих итераций, начиная с некоторого начального значения

параметров θ :

$$\theta := \theta + \alpha \nabla \ln L(\theta) = \theta + \alpha \sum_{i=1}^m (y^{(i)} - f(\theta^T x^{(i)})) x^{(i)}, \alpha > 0.$$

Метод градиентного спуска

- Метод нахождения локального минимума или максимума функции с помощью движения вдоль градиента.
- Пусть целевая функция имеет вид:
- И задача оптимизации задана следующим образом:


$$F(\vec{x}) \rightarrow \min_{\vec{x} \in X} \quad F(\vec{x}) : X \rightarrow \mathbb{R}.$$

- Основная идея метода заключается в том, чтобы идти в направлении наискорейшего спуска, а это направление задаётся антиградиентом $-\nabla F$:

$$\vec{x}^{[j+1]} = \vec{x}^{[j]} - \lambda^{[j]} \nabla F(\vec{x}^{[j]})$$

- $\lambda^{[j]}$ задаёт скорость градиентного спуска и может быть выбрана
 - постоянной (в этом случае метод может расходиться);
 - убывающей в процессе градиентного спуска;
 - гарантирующей наискорейший спуск:

$$\lambda^{[j]} = \operatorname{argmin}_{\lambda} F(\vec{x}^{[j+1]}) \quad \nabla = \frac{\partial}{\partial x_1} \vec{e}_1 + \frac{\partial}{\partial x_2} \vec{e}_2 + \dots + \frac{\partial}{\partial x_n} \vec{e}_n$$



Регрессионные модели

$M_x[Y] = \varphi(X)$ – **парная регрессия**,

$M_x[Y] = \varphi(X_1, \dots, X_m)$ – **множественная регрессия**,

где $\varphi(X) \neq \text{const}$,

X – объясняющая, входная, предсказывающая, экзогенная, неслучайная переменная, фактор, регрессор, факторный признак;

Y – зависимая, объясняемая, выходная, результирующая, эндогенная, случайная переменная, результирующий признак.

Пример:

Парная регрессия

- Мы хотим определить зависимость между продажами и затратами на рекламу.
- y – продажи.
- x – рекламные расходы.

Пример:

Множественная регрессия

- Мы хотим определить связь между потреблением, доходом семьи, финансовыми активами семьи и размером семьи.
- y – потребительские расходы.
- x_1 – доход семьи.
- x_2 – финансовые активы семьи.
- x_3 – размер семьи.

Регрессионные уравнения

$Y = M[Y/x] + \varepsilon = \varphi(x) + \varepsilon$ – уравнение парной регрессии,

$Y = M[Y/x_1, \dots, x_m] + \varepsilon = \varphi(x_1, \dots, x_m) + \varepsilon$ – уравнение множественной регрессии,

где ε – **случайный фактор (остаток)**, обусловленный многими причинами.

В зависимости от вида функции $\varphi(x)$ модели делятся на **линейные** и **нелинейные**.

Причины обязательного присутствия случайного фактора

1. Невключение в модель всех объясняющих переменных.
2. Неправильный выбор функциональной формы модели.
3. Агрегирование переменных (факторы представляют собой комбинацию других переменных).
4. Ошибки измерений.
5. Ограниченность статистических данных.
6. Непредсказуемость человеческого фактора.

Этапы построения качественного уравнения регрессии

1. Определение конечных целей моделирования, набора участвующих в модели факторов и их роли (**постановочный** этап).
2. Предмодельный анализ сущности изучаемого явления (**априорный** этап).
3. Сбор необходимой статистической информации (**информационный** этап).


Этапы построения качественного уравнения регрессии

4. Выбор формулы уравнения регрессии (**спецификация** уравнения регрессии).
5. Определение параметров выбранного уравнения (**параметризация**).
6. Анализ качества уравнения и проверка его адекватности эмпирическим данным, совершенствование уравнения (**верификация**).

Выбор формы парной регрессии

В случае парной регрессии выбор формулы обычно осуществляется по графическому изображению реальных статистических данных в виде точек (***корреляционное поле*** или ***диаграмма рассеивания***).

Примеры взаимосвязи между переменными




- а) Взаимосвязь между Y и X близка к линейной: $Y = a + bX$
- б) Взаимосвязь близка к квадратической: $Y = a + bX + cX^2$
- в) Взаимосвязь между Y и X отсутствует. Какую бы мы ни выбрали форму связи, результаты проверки ее качества будут неудачными

Парная линейная регрессия

Модель линейной регрессии является наиболее распространенной (и простой) зависимостью между переменными, а также может служить начальной точкой анализа.

Модель Кейнса

Рассмотрим модель Кейнса зависимости частного потребления C от располагаемого дохода I : $C = C_0 + bI$,
где C_0 – величина автономного потребления, b – предельная склонность к потреблению ($0 < b \leq 1$)



Модель парной линейной регрессии

Теоретическая парная линейная регрессионная модель:

$$y_i = M[Y / X = x_i] + \varepsilon_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

где β_0, β_1 – теоретические коэффициенты регрессии,
 ε_i – случайное отклонение.

В общем виде теоретическую парную линейную регрессионную модель будем представлять в виде:

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

Задачи линейного регрессионного анализа

Задачи линейного регрессионного анализа состоят в том, чтобы по имеющимся статистическим данным (x_i, y_i) , $i = 1, 2, \dots, n$, для переменных X и Y :

- а) получить наилучшие оценки параметров β_0 и β_1 ;
- б) проверить статистические гипотезы о параметрах модели;
- в) проверить, адекватность модели данным наблюдений.

Эмпирическое уравнение регрессии

По выборке ограниченного объема нельзя точно определить теоретические значения β_0 и β_1 .

Можно лишь построить **эмпирическое уравнение регрессии**:

$$\hat{y}_i = b_0 + b_1 x_i$$

где b_0 и b_1 – оценки параметров β_0 и β_1

эмпирические

$\hat{y}_i$ **коэффициенты регрессии**).

– оценка условного м. о. $M[Y/X = x_i]$.

Эмпирическое уравнение регрессии


В результате имеем: $y_i = b_0 + b_1x_i + e_i$

где e_i – оценка теоретического случайного отклонения ε_i .

Оценки b_0 и b_1 отличаются от истинных значений β_0 и β_1 , что приводит к несовпадению эмпирической и теоретической линий регрессии. По различным выборкам из одной и той же генеральной совокупности получают разные значения оценок коэффициентов регрессии.

Эмпирическое и теоретическое уравнения регрессии

Соотношение между теоретическим и эмпирическим уравнениями регрессии схематично имеет вид:



Задача определения коэффициентов регрессии

Задача состоит в нахождении по выборке данных оценок b_0 и b_1 так, чтобы построенная линия регрессии была **наилучшей в определенном смысле** среди всех других прямых. Решение основано на минимизации:

$$g(y_i, x_i, b_0, b_1) \rightarrow \min, \quad i = \overline{1, n}$$

где g – некоторая функция.

Метод наименьших квадратов

Наиболее распространена **методом наименьших квадратов (МНК)**, реализующий минимизацию суммы квадратов отклонений:


$$\sum_{i=1}^n (y_i - b_0 - b_1 x_i)^2 = \sum_{i=1}^n e_i^2 \rightarrow \min$$

Основные особенности МНК:

- 1) Он наиболее простой с вычислительной точки зрения.
- 2) Оценки коэффициентов регрессии по МНК при определенных предпосылках обладают рядом оптимальных свойств.

Метод наименьших квадратов

Пусть по выборке данных (x_i, y_i) , $i = 1, 2, \dots, n$, требуется определить оценки b_0 и b_1 эмпирического уравнения регрессии:



Метод наименьших квадратов

В этом случае минимизируется функция:

$$Q(b_0, b_1) = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - b_0 - b_1 x_i)^2.$$

Т.к. функция $Q(b_0, b_1)$ непрерывна, выпукла и ограничена снизу, то она имеет минимум.

Необходимым условием минимума $Q(b_0, b_1)$ является равенство нулю ее частных производных по неизвестным параметрам b_0 и b_1 .

Метод наименьших квадратов

Приравняем нулю частные производные и затем разделим на n оба уравнения:

$$\begin{cases} \frac{\partial Q}{\partial b_0} = -2 \sum (y_i - b_0 - b_1 x_i) = 0 \\ \frac{\partial Q}{\partial b_1} = -2 \sum (y_i - b_0 - b_1 x_i) x_i = 0 \end{cases} \Rightarrow \begin{cases} nb_0 + b_1 \sum x_i = \sum y_i \\ b_0 \sum x_i + b_1 \sum x_i^2 = \sum x_i y_i \end{cases}$$

$$\Rightarrow \begin{cases} b_0 + b_1 \bar{x} = \bar{y} \\ b_0 \bar{x} + b_1 \bar{x}^2 = \overline{xy} \end{cases}$$

Оценки метода наименьших квадратов

Решив последнюю систему уравнений, получим:

$$b_1 = \frac{\overline{xy} - \bar{x} \cdot \bar{y}}{\overline{x^2} - \bar{x}^2} = \frac{Cov(x, y)}{Var(x)} = r_{xy} \sqrt{\frac{Var(y)}{Var(x)}}$$

$$b_0 = \bar{y} - b_1 \bar{x}$$

Матричная форма записи

$$\mathbf{X} = \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \dots & \dots \\ 1 & x_n \end{pmatrix} \quad \mathbf{Y} = \begin{pmatrix} y_1 \\ y_2 \\ \dots \\ y_n \end{pmatrix} \quad \mathbf{B} = \begin{pmatrix} b_0 \\ b_1 \end{pmatrix} \quad \mathbf{e} = \mathbf{Y} - \mathbf{XB}$$

МНК эквивалентен ортогональности матрицы $\mathbf{X}$ и вектора $\mathbf{e}$:

$$\mathbf{X}^T \mathbf{e} = \mathbf{0} \quad \mathbf{X}^T (\mathbf{Y} - \mathbf{XB}) = \mathbf{0} \Rightarrow \mathbf{B} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}$$

Выводы

1. Оценки МНК являются функциями от выборки, что позволяет их легко рассчитать.
2. Оценки МНК являются точечными оценками теоретических коэффициентов регрессии.
3. Эмпирическая прямая регрессии обязательно проходит через точку $(\bar{x}, \bar{y})$.

Выводы

4. Эмпирическое уравнение регрессии построено так, что $\sum e_i = 0$, $\bar{e} = 0$.
5. Случайные отклонения e_i не коррелированы с наблюдаемыми значениями y_i зависимой переменной Y .
6. Случайные отклонения e_i не коррелированы с наблюдаемыми значениями x_i независимой переменной X .

Другие методы определения коэффициентов регрессии

Другие методы определения коэффициентов регрессии:

- метод наименьших модулей (МНМ),
- метод моментов (ММ),
- метод максимального правдоподобия (ММП).


Пример (А) построения уравнения регрессии

При анализе зависимости объема потребления Y (у.е.) домохозяйства от располагаемого дохода X (у.е.) отобрана выборка объема $n = 12$ (помесячно в течение года), результаты которой приведены в таблице:

i	1	2	3	4	5	6	7	8	9	10	11	12
x_i	107	109	110	113	120	122	123	128	136	140	145	150
y_i	102	105	108	110	115	117	119	125	132	130	141	144

Пример (А) построения уравнения регрессии

Для определения вида зависимости построим корреляционное поле:



Пример (А) построения уравнения регрессии

По расположению точек на корреляционном поле делаем предположение о линейной зависимости:

$$\hat{Y} = b_0 + b_1 X.$$

Согласно МНК, имеем:

$$b_1 = \frac{\overline{xy} - \bar{x} \cdot \bar{y}}{\overline{x^2} - \bar{x}^2} = \frac{15298,08 - 125,25 \cdot 120,67}{15884,75 - (125,25)^2} = \frac{184,583}{197,188} = 0,9361$$

$$b_0 = \bar{y} - b_1 \bar{x} = 120,67 - 0,9361 \cdot 125,25 = 3,423$$

Пример (А) построения уравнения регрессии

Т.о., уравнение парной линейной регрессии имеет вид:

$$\hat{Y} = 3,423 + 0,9361X$$

Изобразим данную прямую регрессии на корреляционном поле. По этому уравнению рассчитаем $\hat{y}_i$, а также $e_i = y_i - \hat{y}_i$. Для анализа степени линейной зависимости вычислим:

$$r_{xy} = \frac{\overline{xy} - \bar{x}\bar{y}}{\sqrt{\overline{x^2} - \bar{x}^2} \sqrt{\overline{y^2} - \bar{y}^2}} = \frac{184,1625}{14,04 \cdot 13,23} = 0,9914$$

Отсюда можно сделать вывод о сильной прямой линейной зависимости между переменными.

Пример (А). Таблица расчетов по МНК

№№	x_i	y_i	x_i^2	$x_i y_i$	y_i^2	$\hat{y}_i$	e_i	e_i^2
1	107	102	11449	10914	10404	103,58	-1,583	2,507
2	109	105	11881	11445	11025	105,46	-0,455	0,207
3	110	108	12100	11880	11664	106,39	1,609	2,587
4	113	110	12769	12430	12100	109,20	0,800	0,641
5	120	115	14400	13800	13225	115,75	-0,752	0,566
6	122	117	14884	14274	13689	117,62	-0,624	0,390
7	123	119	15129	14637	14161	118,56	0,440	0,193
8	128	125	16384	16000	15625	123,24	1,759	3,094
9	136	132	18496	17952	17424	130,73	1,270	1,614
10	140	130	19600	18200	16900	134,47	-4,474	20,015
11	145	141	21025	20445	19881	139,15	1,846	3,407
12	150	144	22500	21600	20736	143,83	0,165	0,027
Сумма	1503	1448	190617	183577	176834	-	$1,4 \cdot 10^{-14}$	35,249
Среднее	125,25	120,67	15884,75	15298,1	14736,2	-	-	-

Постановка задачи

Рассмотрим так называемую бинарную задачу классификации, т.е. такую задачу классификации, где переменная отклика может принимать только одно из двух значений (в то время как число факторов может быть любым). Приведём некоторые примеры задач бинарной классификации:

Задача диагностики: в медицине речь идёт об установлении у пациента некоторого конкретного заболевания, т.е. принятие решение состоит в выборе из двух суждений:

Предварительный диагноз подтверждается;

Предварительный диагноз не подтверждается.

Обучающая выборка здесь – данные о результатах анализов и прочие характеристики анамнеза некоторого числа n пациентов. Для каждого из них известно значение переменной отклика u , принимающей одно из двух значений:

0 – у пациента нет предполагаемого заболевания,

1 – предполагаемое заболевание установлено.

Нужно получить инструментарий, позволяющий спрогнозировать значение переменной отклика u для любого нового пациента (о котором известны только значения факторов).

Можно привести аналогичные постановки задачи диагностики, возникающие, например, в технике, в теории и практике контроля качества и т.д.

Скоринговые модели: название этих моделей происходит от английского «scoring» – подсчет очков в игре. Чаще всего применяется в банковской сфере и других областях, где нужно, например, предсказать поведение клиента (в частности, для того, чтобы принять решение об одобрении ему кредита или об отказе в выдаче кредита) на основе ряда признаков. Это, например, могут быть: возраст заявителя; средний доход за указанный период времени; общий стаж работы; стаж работы на последнем месте; возраст; пол; наличие/отсутствие судимости.....

Постановка задачи

Обучающая выборка здесь представляет собой набор данных о перечисленных выше характеристиках некоторого числа n клиентов банка. Для каждого из которых известно значение переменной отклика y , принимающей одно из двух значений:

0 – клиент имел проблемы с возвратом кредита,

1 – клиент оказался благонадёжным.

Задачи бинарной классификации возникают всякий раз, когда речь идёт о выборе между двух вариантов, например,

– сотрудник Отдела технического контроля (или автомат, осуществляющий проверку) решает, признать инспектируемый объект пригодным или бракованным;

– поисковая система, обнаружив тот или иной документ, «решает», включать его в результат поиска или нет; – устройство идентификации личности (или же вахтёр) решает, пропустить человека в помещение (предоставить ему доступ к информации) или нет;

– клиент (частное лицо или корпорация) принимает решение о том, размещать ли деньги в предлагаемом банке или нет;

– инвестор решает: финансировать проект или нет...

Список этот можно продолжать бесконечно

Принцип построения логистической регрессионной модели

Рассмотрим принцип построения логистической регрессионной модели на примере скоринговой модели. Предположим, что представителю кредитного отдела банка нужен инструментарий для поддержки принятия решения об одобрении кредита заявителю (или об отказе в кредите).

В распоряжении банка есть некоторое количество (n) анкет, которые были заполнены клиентами на момент обращения за кредитом. В этих анкетах указаны данные заявителя (размер зарплаты, возраст, общий стаж работы, стаж работы на последнем месте работы, пол и т.д.) – будем называть их факторами (предикторами), а также – признак того, был ли клиент благонадёжным (не имел проблем с возвратом кредита) или нет – этот признак будем называть переменной отклика. Таким образом, обучающую выборку можно представить в виде следующей таблицы:

	Факторы					Переменная отклика
i № клиента	X_1 Заработная плата	X_2 Возраст	X_3 Общий стаж	...	X_m	y надёжность клиента
1	$X_{1,1}$	$X_{1,2}$	$X_{1,3}$	...	$X_{1,m}$	1
...						0
i						1
...						1
n	$X_{n,1}$	$X_{n,2}$	$X_{n,3}$	...	$X_{n,m}$	0

Принцип построения логистической регрессионной модели

Для наглядности рассмотрим сначала однофакторный случай – ограничимся изучением влияния заработной платы клиента на его платёжеспособность.

Построим облако точек – см. Рис.1.




Рис.1 Зависимость между зарплатой и платёжеспособностью клиентов

Принцип построения логистической регрессионной модели

Как видно из Рис.1, линейная регрессионная модель неприменима для описания зависимости между зарплатой и платёжеспособностью клиентов. Необходима другая модель. В основе логистической регрессионной модели лежит следующий принцип: в отличие от линейной регрессионной модели, прогнозируется не само значение переменной отклика (т.е. номера класса), а вероятность того, что переменная отклика принимает значение 1. На основе этой вычисленной вероятности затем принимается решение, к какому классу следует отнести исследуемый объект.

Несмотря на то, что решение, казалось бы, очевидно: нужно отнести объект к тому классу, для которого вероятность (вычисленная согласно логистической модели) больше (т.е. сравнивать вычисленную вероятность с «пороговым»

значением, равным 50%). Однако при принятии решения необходимо учитывать социальные, экономические или иные последствия ошибок двух типов: принять неверную гипотезу; отвергнуть верную гипотезу.

Например,

В задаче медицинской диагностики: врач предполагает, что пациент страдает некоторым заболеванием. Если это предположение неверно, но гипотеза принята, это может привести, как минимум, к лишним расходам пациента на ненужные лекарства и процедуры, а в худшем случае – к ухудшению состояния пациента вследствие неправильного лечения; Если же предварительный диагноз был верным, но по итогам применения теста ошибочно отвергнут, то пациент не получит своевременного лечения, что чревато серьёзными последствиями.

В задаче оценки благонадёжности потенциального клиента банка: Одобрение кредита неблагонадёжному клиенту грозит банку потерями вследствие невозврата кредита, неодобрение благонадёжному – упущенной прибылью. Поэтому «пороговое» значение вероятности должно устанавливаться исследователем из условия минимизации возможных потерь, вызванных совершением ошибки того или иного типа.

Математическая постановка задачи

Для простоты сначала рассмотрим однофакторную логистическую модель. Поскольку при каждом значении фактора x исследуемая случайная величина y (номер класса) может принимать лишь один вид:

Значения с.в. (номер класса) y	1	0
Вероятности при значении признака, равном x	$p(y = 1 x)$	$p(y = 0 x)$

Иными словами, распределение с.в. y (номера класса) (при каждом фиксированном x) есть *распределение Бернулли* с параметром $p(y=1|x)$.

Обозначим $p(y = 1 | x) \equiv f(x)$

Будем искать функцию $f(x)$ (т.е. вероятность того, что клиент с заработной платой X окажется платёжеспособным) в таком виде, чтобы график функции был как можно ближе к точкам, показанным на Рис.1, т.е. график искомой функции должен иметь S-образную форму.

Этим свойством обладает так называемое *logit-преобразование*, задаваемое формулой:

$$\varphi(z) \equiv \frac{1}{1+e^{-z}}. \quad (1)$$

График функции (1) показан на Рис.2.




Рис.2 График logit-функции

Математическая постановка задачи

Будем искать вероятность (1) в виде:

$$f(x) = \frac{1}{1 + e^{-(\beta_0 + \beta x)}}. \quad (2)$$

Здесь параметры β_0 и β определяют кривизну и смещение кривой (см. Рис.3) :




Рис.3. Графики функции (2) при $\beta_0=10$, $\beta=0.3$ (красная кривая) и при $\beta_0=-2$, $\beta=0.8$ (синяя кривая)

Таким образом, должного «поведения» графика функции (2) будем добиваться за счёт правильного выбора параметров модели β_0, β .

Нахождение параметров логистической модели

Используя формулу (2), запишем ряд распределения вероятностей переменной отклика следующим образом:

Значения с.в. (номер класса) y	1	0
Вероятности при значении признака, равном x	$\frac{1}{1 + e^{-(\beta_0 + \beta x)}}$	$\frac{e^{-(\beta_0 + \beta x)}}{1 + e^{-(\beta_0 + \beta x)}}$

В общем виде вероятность того, что переменная отклика (номер класса) примет значение y при фиксированном значении фактора (x) равна

$$p(y|x) = \left(\frac{1}{1 + e^{-(\beta_0 + \beta x)}} \right)^y \left(\frac{e^{-(\beta_0 + \beta x)}}{1 + e^{-(\beta_0 + \beta x)}} \right)^{(1-y)} \quad (3)$$

Будем искать параметры β_0, β методом максимального правдоподобия.

Нахождение параметров логистической модели

Замечание. Напомним, что *функция правдоподобия* (англ.: *likelihood function*) – это плотность совместного распределения выборки из параметрического распределения, рассматриваемая как *функция параметра*. Иными словами, если распределение некоторой с.в. ξ зависит от параметра Θ (это может быть скалярная величина или вектор), то для выборки $x_1, \dots, x_n$ значение функции правдоподобия имеет вид:

$$L(\Theta, x_1, \dots, x_n) \equiv \prod_{i=1}^n f(\Theta, x_i),$$

где $f(\Theta, x_i)$ – значение плотности с.в. ξ в точке x_i (если с.в. ξ непрерывна) или значение вероятности $p(\xi = x_i)$, если с.в. ξ дискретна.

Метод максимального правдоподобия предполагает, что в качестве оценки неизвестного параметра Θ , выбирается то его значение, при котором достигается максимум функции правдоподобия, т.е.

$$\hat{\Theta} = \arg \max_{\Theta} L(\Theta, x_1, \dots, x_n)$$

Нахождение параметров логистической модели

Считая, что наблюдения, по результатам которых получена обучающая выборка, независимы, запишем функцию правдоподобия как произведение:

$$L(\beta_0, \beta) \equiv \prod_{i=1}^n p_i^{y_i} (1 - p_i)^{1-y_i}, \quad (4)$$

где i – номер наблюдения (т.е. в рассматриваемом примере – номер клиента банка, номер строки в таблице исходных данных), p_i есть вероятность того, что при тех значениях признаков, которые указаны в i -ой строке таблицы исходных данных, переменная отклика Y примет значение y_i , $i = 1, \dots, n$. (Как нетрудно видеть, для тех номеров i , для которых $y_i = 1$, i -ый сомножитель в формуле (4) равен p_i , а для тех i , для которых $y_i = 0$, i -ый сомножитель в формуле (4) равен $1 - p_i$.) Вероятность p_i вычисляется по формуле (3), где в качестве $\mathbf{x}$ используются значения, записанные в i -ой строке таблицы исходных данных.

Нахождение параметров логистической модели

Согласно *принципу максимального правдоподобия* в качестве искомого вектора коэффициентов β_0, β тот вектор, при котором достигается максимум функции (4).

На практике вместо максимизации функции (4) обычно решают задачу максимизации её логарифма, т.е. функции

$$\ln(L(\beta_0, \beta)) \equiv \sum_{i=1}^n (y_i \ln p_i + (1 - y_i) \ln(1 - p_i)) \quad (5)$$

Очевидно, что функция (5) является дифференцируемой (по переменным β_0, β). Однако (в отличие, например, от функции, минимизируемой методом наименьших квадратов в задаче построения уравнения линейной регрессии), искомые значения β_0, β , максимизирующие функцию (5), не могут быть найдены по явным формулам. Для максимизации функции (5) используются приближённые итерационные методы, например, градиентный метод или метод Ньютона¹.

Понятно, что случай, когда число факторов m больше 1, отличается от рассмотренного тем, что во всех приведённых выше формулах сумма $\beta_0 + \beta_1 x$ будет заменена на $\beta_0 + \beta_1 x_1 + \dots + \beta_m x_m$.

Применение логистической модели

Применение логистической модели для прогнозирования значений переменной отклика (номера класса) Формула (3) даёт нам вероятность того, что при заданном наборе факторов (предикторов) $x \equiv (x_1, \dots, x_m)$ прогнозируемый признак $y = 1$ (т.е. исследуемый объект принадлежит классу с номером 1). В зависимости от значения этой вероятности мы либо принимаем гипотезу о том, что $y = 1$, либо отвергаем её, полагая, что $y = 0$ (т.е. исследуемый объект принадлежит классу с номером 0). Обычно в качестве пороговой вероятности для принятия гипотезы принимают значение 0,5. Однако, как было сказано выше, в зависимости от того, какие последствия могут вытекать из ошибочного отнесения объекта к классу 1 (когда на самом деле он принадлежит классу 0), можно увеличить пороговое значение этой вероятности.

На приведённом ниже Рис.4 рассмотренное ранее облако точек (координаты которых есть данные о зарплате (абсцисса) и благонадёжности (ордината) клиентов банка) совмещено с логистической кривой, параметры которой β_0, β , найдены методом максимального правдоподобия.




Рис.4. Одномерная логистическая кривая с оптимальными значениями параметров, найденными для представленных на графике данных о зарплате и благонадёжности клиентов банка.

Примеры

Приведём несколько примеров использования построенной логистической регрессионной модели.

Предположим, что заявление на выдачу кредита подали клиенты банка с зарплатой в 10, 13, 15, 16 и 21 тыс. руб. Вычислим для них значение вероятности «попадания в класс благонадёжных» и нанесём соответствующие точки на график. Результат показан на Рис.5.

Установим «пороговое» значение вероятности того, что клиент окажется кредитоспособным. Понятно, что чем больше мы боимся одобрить кредит неплатёжеспособному клиенту, тем выше должна быть эта вероятность. Пусть например это «пороговое» значение вероятности = 0,6.




Рис.5. Спрогнозированные значения вероятностей попадания клиентов (с указанной зарплатой) в класс благонадёжных

Пример

Таким образом,

- а) Клиента с зарплатой в 10 т.р. логистическая модель отнесёт к классу неблагонадёжных (вычисленное значение вероятности попасть в класс благонадёжных = 0.001763099).
- б) Клиента с зарплатой в 13 т.р. логистическая модель отнесёт к классу неблагонадёжных (вычисленное значение вероятности попасть в класс благонадёжных = 0.1010118).
- с) Клиента с зарплатой в 15 т.р. логистическая модель отнесёт к классу благонадёжных (вычисленное значение вероятности попасть в класс благонадёжных = 0.6416557).
- д) Клиента с зарплатой в 16 т.р. логистическая модель отнесёт к классу благонадёжных (вычисленное значение вероятности попасть в класс благонадёжных = 0.8772727).
- е) Клиента с зарплатой в 21 т.р. логистическая модель отнесёт к классу благонадёжных (вычисленное значение вероятности попасть в класс благонадёжных = 0.999862).




Рис.5. Спрогнозированные значения вероятностей попадания клиентов (с указанной зарплатой) в класс благонадёжных

В рассмотренном примере мы использовали всего один фактор (предиктор) —заработную плату клиентов банка. Понятно, что на платёжеспособность клиентов влияет не только заработная плата, но и другие факторы (например, возраст, стаж, наличие долговых обязательств и пр.). Рассмотрим общий случай задачи. Таким образом, в рассмотренном примере логистическая регрессионная модель позволяет вычислить вероятность того, что при заданном значении среднемесячной зарплаты клиент банка окажется благонадёжным (вовремя выплатит кредит). Дальнейшее принятие решений – дело представителя кредитного отдела банка.

Пример

Заметим, что для бинарной с.в., количество информации, содержащейся в вероятности $p(y=1)$ равна количеству информации, содержащейся в так называемом «*отношении шансов*» (англ.: odds ratio):

$$OR = \frac{p(y = 1)}{p(y = 0)}$$

Для рассмотренной модели отношение шансов равно

$$OR = e^{(\beta_0 + \beta x)}$$

Соответственно, натуральный логарифм от отношения шансов равен

$$\ln(OR) = \beta_0 + \beta x$$

То есть получили линейную модель, которая, в отличие от случая линейной регрессии, описывает поведение не самой переменной отклика, а отношения шансов для вероятностей её значений.

ROC-анализ

Модель	Фактически положительно	Фактически отрицательно
Положительно	TP	FP
Отрицательно	FN	TN

TP (True Positives) — верно классифицированные положительные примеры (так называемые истинно положительные случаи).

TN (True Negatives) — верно классифицированные отрицательные примеры (истинно отрицательные случаи).

FN (False Negatives) — положительные примеры, классифицированные как отрицательные (ошибка I рода). Это так называемый «ложный пропуск» — когда интересующее нас событие ошибочно не обнаруживается (ложно отрицательные примеры).

FP (False Positives) — отрицательные примеры, классифицированные как положительные (ошибка II рода). Это ложное обнаружение, т.к. при отсутствии события ошибочно выносится решение о его присутствии (ложно положительные случаи).

Что является положительным событием, а что — отрицательным, зависит от конкретной задачи. Например, если мы прогнозируем вероятность наличия заболевания, то положительным исходом будет класс «Больной пациент», отрицательным — «Здоровый пациент». И наоборот, если мы хотим определить вероятность того, что человек здоров, то положительным исходом будет класс «Здоровый пациент», и так далее.

ROC-анализ

Что является положительным событием, а что — отрицательным, зависит от конкретной задачи. Например, если мы прогнозируем вероятность наличия заболевания, то положительным исходом будет класс «Больной пациент», отрицательным — «Здоровый пациент». И наоборот, если мы хотим определить вероятность того, что человек здоров, то положительным исходом будет класс «Здоровый пациент», и так далее.

При анализе чаще оперируют не абсолютными показателями, а относительными — долями (rates), выраженными в процентах:

- Доля истинно положительных примеров (True Positives Rate): $TPR = \frac{TP}{TP+FN} \cdot 100\%$
- Доля ложно положительных примеров (False Positives Rate): $FPR = \frac{FP}{TN+FP} \cdot 100\%$

Введем еще два определения: чувствительность и специфичность модели. Ими определяется объективная ценность любого бинарного классификатора.

Чувствительность (Sensitivity) — это и есть доля истинно положительных случаев:

$$S_e = TPR = \frac{TP}{TP+FN} \cdot 100\%$$

Специфичность (Specificity) — доля истинно отрицательных случаев, которые были правильно идентифицированы моделью:

$$S_p = \frac{TN}{TN+FP} \cdot 100\%$$

Заметим, что $FPR = 100 - S_p$

Попытаемся разобраться в этих определениях.

ROC-анализ

ROC-анализ тесно связан с бинарной логистической регрессией и применяется для оценки качества моделей: позволяет выбрать аналитику модель с наилучшей прогностической силой, проанализировать чувствительность и специфичность моделей, подобрать порог отсечения.

ROC-кривая (Receiver Operator Characteristic) — кривая, которая наиболее часто используется для представления результатов бинарной классификации в машинном обучении. Название пришло из систем обработки сигналов. Поскольку классов два, один из них называется классом с положительными исходами, второй — с отрицательными исходами. ROC-кривая показывает зависимость количества верно классифицированных положительных примеров от количества неверно классифицированных отрицательных примеров.

В терминологии ROC-анализа первые называются истинно положительным, вторые — ложно отрицательным множеством. При этом предполагается, что у классификатора имеется некоторый параметр, варьируя который, мы будем получать то или иное разбиение на два класса. Этот параметр часто называют порогом, или точкой отсечения (cut-off value). В зависимости от него будут получаться различные величины ошибок I и II рода.

В логистической регрессии порог отсечения изменяется от 0 до 1 — это и есть расчетное значение уравнения регрессии. Будем называть его рейтингом.

Для понимания сути ошибок I и II рода рассмотрим четырехпольную таблицу сопряженности (confusion matrix), которая строится на основе результатов классификации моделью и фактической (объективной) принадлежностью примеров к классам.

ROC-анализ

Попытаемся разобраться в этих определениях.

Модель с высокой чувствительностью часто дает истинный результат при наличии положительного исхода (обнаруживает положительные примеры). Наоборот, модель с высокой специфичностью чаще дает истинный результат при наличии отрицательного исхода (обнаруживает отрицательные примеры). Если рассуждать в терминах медицины — задачи диагностики заболевания, где модель классификации пациентов на больных и здоровых называется диагностическим тестом, то получится следующее:

- Чувствительный диагностический тест проявляется в гипердиагностике — максимальном предотвращении пропуска больных.
- Специфичный диагностический тест диагностирует только доподлинно больных. Это важно в случае, когда, например, лечение больного связано с серьезными побочными эффектами и гипердиагностика пациентов не желательна.

ROC-кривая получается следующим образом:

- Для каждого значения порога отсечения, которое меняется от 0 до 1 с шагом dx (например, 0,01) рассчитываются значения чувствительности Se и специфичности Sp . В качестве альтернативы порогом может являться каждое последующее значение примера в выборке.
- Строится график зависимости: по оси Y откладывается чувствительность Se , по оси X — $FPR=100-Sp$ — доля ложно положительных случаев.

Задание

Задание на практическую работу в приложенных файлах и состоит из двух частей.

Часть 1.

Построить прогностическую модель для набора данных в файле, проверить связь признаков, построить прогностические модели и модели тренда линейного и квадратичного. Оценить погрешность. (Можно использовать язык программирования)

Часть 2.

Разработать прогностическую модель для набора данных диабетических обследований diabetes.txt. Использовать логистическую регрессию, и метод максимального правдоподобия. Коэффициенты логистической регрессии найти с помощью метода градиентного спуска, который необходимо запрограммировать вручную. Разбить выборку на обучающую и тестовую. Вычислить точность классификации.

Применить отбор признаков на основе корреляции: выбрать наилучшее признаковое пространство, имеющее на два измерения меньше исходного. Построить новую модель и вычислить точность классификации. (Используя Python или любой другой язык программирования)

Спасибо за внимание!