

Методичка по методам прогнозирования временных рядов (Практика 7)

1. Основные понятия

Что такое временной ряд?

Временной ряд — это последовательность наблюдений $\{s(t), t = 0, 1, 2, \dots\}$, упорядоченная по времени.

Ключевые свойства временных рядов

Стационарность — статистические характеристики (среднее, дисперсия) не меняются во времени.

- Пример стационарного ряда: колебания температуры около среднего значения
- Пример нестационарного ряда: постоянный рост продаж

Эргодичность — временные средние совпадают с ансамблевыми средними. Это означает, что один длинный ряд содержит всю информацию о процессе.

2. Типовые модели временных рядов

2.1 Модель авторегрессии AR(p)

Идея: текущее значение зависит от p предыдущих значений.

Формула:

$$s(t) = a_1 \cdot s(t-1) + a_2 \cdot s(t-2) + \dots + a_p \cdot s(t-p) + \varepsilon(t)$$

Где:

- a_i — коэффициенты авторегрессии
- $\varepsilon(t)$ — белый шум (случайная ошибка)
- p — порядок модели (сколько прошлых значений учитываем)

Примеры:

- **AR(1):** $s(t) = a_1 \cdot s(t-1) + \varepsilon(t)$ — зависит только от предыдущего значения
- **AR(2):** $s(t) = a_1 \cdot s(t-1) + a_2 \cdot s(t-2) + \varepsilon(t)$ — зависит от двух предыдущих

Условие стационарности для AR(1):

$$-1 < a_1 < 1$$

Если $|a_1| \geq 1$, ряд будет расти бесконечно или колебаться с увеличивающейся амплитудой.

На защите могут спросить: "Что будет, если $a_1 = 1.5$?" **Ответ:** Ряд станет нестационарным, будет экспоненциально расти.

2.2 Модель скользящего среднего MA(q)

Идея: текущее значение зависит от текущей и прошлых ошибок.

Формула:

$$s(t) = \varepsilon(t) + b_1 \cdot \varepsilon(t-1) + b_2 \cdot \varepsilon(t-2) + \dots + b_q \cdot \varepsilon(t-q)$$

Где:

- b_j — коэффициенты скользящего среднего

- q — порядок модели

Интуиция: Модель учитывает, как прошлые "шоки" влияют на текущее значение.

2.3 Смешанная модель ARMA(p,q)

Идея: объединяет AR и MA.

Формула:

$$s(t) = a_1 \cdot s(t-1) + \dots + a_p \cdot s(t-p) + \varepsilon(t) + b_1 \cdot \varepsilon(t-1) + \dots + b_q \cdot \varepsilon(t-q)$$

Частные случаи:

- ARMA(1,0) = AR(1) — только авторегрессия
- ARMA(0,1) = MA(1) — только скользящее среднее
- ARMA(1,1) — и то, и другое

На защите могут спросить: "Чем отличается AR от MA?" Ответ:

- AR использует прошлые **значения** ряда
 - MA использует прошлые **ошибки** прогноза
-

3. Экспоненциальное сглаживание (основной метод)

3.1 Формула

$$\tilde{s}(t+1) = \alpha \cdot s(t) + (1-\alpha) \cdot \tilde{s}(t)$$

Где:

- $s(t)$ — фактическое значение в момент t
- $\tilde{s}(t)$ — сглаженное значение в момент t
- α — параметр сглаживания ($0 < \alpha < 1$)

Прогноз: $\hat{s}(t+1) = \tilde{s}(t+1)$

3.2 Как это работает?

Представьте, что вы делаете прогноз погоды:

- Если $\alpha = 0.9$ (близко к 1), вы почти полностью доверяете последнему дню
- Если $\alpha = 0.1$ (близко к 0), вы учитываете долгую историю погоды

Формула по-другому:

$$\tilde{s}(t+1) = \tilde{s}(t) + \alpha \cdot [s(t) - \tilde{s}(t)]$$

Это означает: новый прогноз = старый прогноз + доля от ошибки

3.3 Параметр α — критически важно понимать!

α близко к 0 (например, 0.1):

- ✓ Максимальное сглаживание
- ✓ Минимальная адаптация
- ✓ Большая "память" о прошлом
- ✓ Хорошо для стабильных данных с шумом
- ✗ Медленно реагирует на изменения

α близко к 1 (например, 0.9):

- ✓ Минимальное сглаживание
- ✓ Максимальная адаптация
- ✓ Быстрая реакция на изменения
- ✗ Малая "память"
- ✗ Чувствителен к шуму
- При $\alpha = 1$: наивная модель (прогноз = последнее значение)

Оптимальные значения:

- $\alpha = 0.1-0.2$ для стабильных процессов
- $\alpha = 0.3-0.5$ для типичных задач
- $\alpha = 0.6-0.9$ для быстро меняющихся процессов

На защите могут спросить: "Что происходит при $\alpha \rightarrow 0$?" **Ответ:** Максимальное сглаживание, модель почти не реагирует на новые данные, прогноз близок к среднему значению всей истории.

3.4 Инициализация

Два способа:

1. $\tilde{s}(0) = s(0)$ — просто берем первое значение
2. $\tilde{s}(0) = \text{среднее первых } n \text{ значений}$ — более стабильно

4. Адаптивная фильтрация (продвинутый метод)

4.1 Основная идея

В отличие от экспоненциального сглаживания, которое использует один параметр α , адаптивная

фильтрация использует **несколько весов**, которые **автоматически подстраиваются** под данные.

4.2 Формула прогноза

$$\hat{s}(t+1) = w_1 \cdot s(t) + w_2 \cdot s(t-1) + \dots + w_\lambda \cdot s(t-\lambda+1)$$

Где:

- w_j — весовые коэффициенты (веса)
- λ — размер окна (сколько прошлых значений используем)

Пример с $\lambda = 3$:

$$\hat{s}(t+1) = w_1 \cdot s(t) + w_2 \cdot s(t-1) + w_3 \cdot s(t-2)$$

4.3 Адаптация весов

После каждого прогноза веса корректируются:

$$w_j(\text{новый}) = w_j(\text{старый}) + k_\gamma \cdot e(t+1) \cdot s(t+1-j)$$

Где:

- $e(t+1)$ — ошибка прогноза = $s(t+1) - \hat{s}(t+1)$
- k_γ — коэффициент обучения

Формула для k_γ :

$$k_\gamma = \alpha_r / [s^2(t) + s^2(t-1) + \dots + s^2(t-\lambda+1)]$$

Где α_r — регулировочный коэффициент (обычно = 1)

4.4 Как работает адаптация?

Пример:

1. Делаем прогноз с текущими весами
2. Смотрим на ошибку
3. Если ошибка большая — **сильно** меняем веса
4. Если ошибка маленькая — **чуть-чуть** меняем веса
5. Нормализуем веса (чтобы сумма = 1)

Интуиция: Веса "учатся" на ошибках, как нейронная сеть!

4.5 Нормализация весов

После адаптации веса могут быть любыми, но для корректного прогноза их сумма должна быть 1:

$$w_j(\text{нормализованный}) = w_j / (w_1 + w_2 + \dots + w_\lambda)$$

На защите могут спросить: "Зачем нормализовать веса?" **Ответ:** Чтобы прогноз оставался в разумных пределах и веса имели интерпретацию как доли вклада каждого наблюдения.

4.6 Выбор размера окна λ

- $\lambda = 2-3$ — быстрая адаптация, высокая чувствительность
- $\lambda = 4-6$ — баланс между адаптацией и стабильностью
- $\lambda = 7-10$ — медленная адаптация, устойчивость к шуму

На защите могут спросить: "Какое λ выбрать для быстро меняющихся данных?" **Ответ:** Малое λ (2-3), чтобы быстро реагировать на изменения.

5. Метод Хольта (двойное экспоненциальное сглаживание)

5.1 Когда использовать?

Когда во временном ряду есть **линейный тренд** (постоянный рост или падение).

5.2 Формулы

Уровень:

$$L(t) = \alpha \cdot s(t) + (1-\alpha) \cdot [L(t-1) + T(t-1)]$$

Тренд:

$$T(t) = \beta \cdot [L(t) - L(t-1)] + (1-\beta) \cdot T(t-1)$$

Прогноз на k шагов вперед:

$$\hat{s}(t+k) = L(t) + k \cdot T(t)$$

Где:

- **L(t)** — уровень ряда (текущее значение без тренда)
- **T(t)** — тренд (скорость роста)
- **α** — параметр сглаживания уровня
- **β** — параметр сглаживания тренда
- **k** — на сколько шагов вперед прогнозируем

5.3 Инициализация

$$L(0) = s(0)$$

$$T(0) = s(1) - s(0)$$

Тренд инициализируется как разность первых двух значений.

5.4 Интуиция

Метод отслеживает два компонента:

1. **Куда мы пришли** (уровень L)
2. **Как быстро мы движемся** (тренд T)

Прогноз = текущий уровень + скорость $\times$ время

Пример: Если $L(10) = 100$, $T(10) = 5$, то:

- Прогноз на 1 шаг: $100 + 1 \times 5 = 105$
- Прогноз на 2 шага: $100 + 2 \times 5 = 110$
- Прогноз на 3 шага: $100 + 3 \times 5 = 115$

6. Оценка качества прогноза

6.1 Метрики

MSE (Mean Squared Error):

$$MSE = (1/n) \sum [s(t) - \hat{s}(t)]^2$$

MAE (Mean Absolute Error):

$$\text{MAE} = (1/n) \sum |s(t) - \hat{s}(t)|$$

MAPE (Mean Absolute Percentage Error):

$$\text{MAPE} = (100/n) \sum [|s(t) - \hat{s}(t)| / s(t)]$$

6.2 Свойства ошибки

Для несмещенных оценок:

$$M[e] = 0$$

Математическое ожидание ошибки должно быть нулевым.

Дисперсия ошибки для экспоненциального сглаживания:

$$D[e] \approx (\alpha / (2 - \alpha)) \cdot D[s] \cdot (1 - R(1))$$

Где $R(1)$ — коэффициент автокорреляции первого порядка.

На защите могут спросить: "Что означает $M[e] = 0$?" **Ответ:** Прогноз несмещенный — ошибки в среднем компенсируют друг друга (нет систематического завышения или занижения).

7. Сравнение методов

Экспоненциальное сглаживание vs Адаптивная фильтрация

Критерий	Эксп. сглаживание	Адапт. фильтрация
Параметры	1 параметр (α)	λ весов
Адаптация	Фиксированная	Автоматическая
Сложность	Простая	Средняя
Память	Экспоненциально убывает	Фиксированное окно
Применение	Стационарные ряды	Изменяющаяся структура

Когда что использовать?

Экспоненциальное сглаживание:

- ✓ Стационарный ряд без тренда
- ✓ Нужна простота
- ✓ Данные без резких изменений

Адаптивная фильтрация:

- ✓ Изменяющаяся динамика
- ✓ Нужна автоматическая подстройка
- ✓ Есть вычислительные ресурсы

Метод Хольта:

- ✓ Есть линейный тренд
- ✓ Нужен многошаговый прогноз

- ✓ Данные стабильно растут/падают
-

8. Типичные вопросы на защите

Вопрос 1: "Что означает стационарность?"

Ответ: Стационарность означает, что статистические свойства ряда (среднее, дисперсия) не меняются во времени. Для стационарного ряда график колеблется около постоянного среднего значения.

Вопрос 2: "В чем разница между AR и MA?"

Ответ:

- **AR** (авторегрессия) — текущее значение зависит от **прошлых значений** ряда
- **MA** (скользящее среднее) — текущее значение зависит от **прошлых ошибок** прогноза

Вопрос 3: "Когда $\alpha \rightarrow 0$ в экспоненциальном сглаживании?"

Ответ: Максимальное сглаживание, модель имеет долгую память и медленно реагирует на изменения. Прогноз близок к среднему значению всей истории.

Вопрос 4: "Что такое белый шум $\varepsilon(t)$?"

Ответ: Случайная величина с нулевым средним и постоянной дисперсией, значения которой независимы друг от друга. Это непредсказуемая часть временного ряда.

Вопрос 5: "Как работает адаптация весов?"

Ответ: После каждого прогноза веса корректируются пропорционально ошибке: если прогноз был плохой, веса меняются сильнее. Это похоже на обучение нейронной сети.

Вопрос 6: "Условие стационарности для AR(1)?"

Ответ: $-1 < a_1 < 1$. Если модуль коэффициента больше или равен 1, ряд становится

нестационарным.

Вопрос 7: "Зачем нужна нормализация весов?"

Ответ: Чтобы сумма весов была равна 1, иначе прогноз может уйти в бесконечность. Нормализация сохраняет интерпретацию весов как долей вклада.

Вопрос 8: "Когда использовать метод Хольта?"

Ответ: Когда во временном ряду есть явный линейный тренд (постоянный рост или падение). Простое экспоненциальное сглаживание в этом случае будет давать большие ошибки.

Вопрос 9: "Что такое многошаговый прогноз?"

Ответ: Прогноз не на 1, а на несколько шагов вперед. Например, спрогнозировать продажи не только на завтра, но и на послезавтра, и на неделю вперед.

Вопрос 10: "Зачем комбинировать прогнозы?"

Ответ: Разные методы дают разные прогнозы, и каждый может ошибаться по-своему. Комбинируя их с весами по точности, мы получаем более надежный результат, так как ошибки усредняются.

9. Ответы на тестовые вопросы

- 1. Модель AR(p) выражает текущее значение через: ✓ В) Линейную комбинацию p предыдущих значений**
- 2. Параметр α определяет: ✓ А) Степень сглаживания и скорость адаптации**
- 3. При $\alpha \rightarrow 0$: ✓ В) Максимальное сглаживание**
- 4. Условие стационарности для AR(1): ✓ В) $-1 < a_1 < 1$**
- 5. В ARMA(p,q) параметр q определяет: ✓ В) Порядок скользящего среднего**

6. Адаптивная фильтрация использует: ✓ С) Адаптивно изменяющиеся весовые коэффициенты
7. Адаптация весов основана на: ✓ В) Методе наискорейшего спуска
8. Оптимальный k_γ вычисляется: ✓ В) $k_\gamma = a_r / \Sigma s^2(t)$
9. $M[e]$ для несмещенных оценок: ✓ С) 0
10. Метод Хольта используется для рядов: ✓ В) С линейным трендом
-

10. Практические советы

Структура решения любого задания:

1. **Импорты** — numpy, matplotlib
2. **Исходные данные** — задаем временной ряд
3. **Создание модели** — класс или функция
4. **Обучение** — fit_predict()
5. **Расчет метрик** — MSE, MAE, MAPE
6. **Прогноз на будущее** — forecast_next()
7. **Визуализация** — графики (если требуется)
8. **Выводы** — сравнение методов

Что важно помнить:

1. **Инициализация** — первое значение особенное
2. **Пропуск первых точек** — для них нет прогноза

3. **Нормализация весов** — сумма должна быть 1
 4. **Многошаговый прогноз** — итеративное применение
 5. **Комбинирование** — веса обратно пропорциональны MSE
-

11. Заключение

Ключевые выводы:

1. **AR** моделирует зависимость от прошлых значений
2. **MA** моделирует зависимость от прошлых ошибок
3. **ARMA** объединяет оба подхода
4. **Экспоненциальное сглаживание** — простой эффективный метод с одним параметром
5. **Адаптивная фильтрация** — автоматически подстраивает веса
6. **Метод Хольта** — для рядов с трендом
7. **Комбинирование** методов повышает надежность

Вы готовы к защите, если:

- ✓ Понимаете разницу между AR, MA и ARMA
- ✓ Можете объяснить роль параметра α
- ✓ Знаете, как работает адаптация весов
- ✓ Понимаете условие стационарности
- ✓ Можете обосновать выбор метода

- ✓ Умеее читать и объяснять код

Удачи на защите! 🎯