



МИНОБРНАУКИ РОССИИ
Федеральное государственное-бюджетное образовательное
учреждение высшего образования
«МИРЭА — Российский технологический университет»
РТУ МИРЭА

Институт кибербезопасности и цифровых технологий

(наименование института, филиала)

Кафедра КБ-4 «Интеллектуальные системы информационной безопасности»

(наименование кафедры)

ОТЧЁТ ПО ПРОИЗВОДСТВЕННОЙ ПРАКТИКЕ

(указать вид практики: учебная/производственная)

Научно-исследовательская работа

(указать тип практики в соответствии с учебным планом)

приказ Университета о направлении на практику от «27» января 2026 г. № 555-С

Отчет представлен
к рассмотрению:

Студент группы БМО-01-25 «___» _____ 2026 г. _____
(подпись и расшифровка подписи)

Отчет утвержден.
Допущен к защите:

Руководитель практики
от кафедры «___» _____ 2026 г. _____
(подпись и расшифровка подписи)

Москва 2026 г.



МИНОБРНАУКИ РОССИИ

Федеральное государственное-бюджетное образовательное учреждение высшего образования

«МИРЭА — Российский технологический университет»

РТУ МИРЭА

Институт кибербезопасности и цифровых технологий

(наименование института, филиала)

Кафедра КБ-4 «Интеллектуальные системы информационной безопасности»

(наименование кафедры)

ИНДИВИДУАЛЬНОЕ ЗАДАНИЕ НА ПРОИЗВОДСТВЕННУЮ ПРАКТИКУ

(указать вид практики: учебная/производственная)

Научно-исследовательская работа

(указать тип практики в соответствии с учебным планом)

Студенту 1 курса учебной группы БМО-01-25

Шульгину Владиславу Андреевичу

(фамилия, имя и отчество)

Место и время практики: Лаборатория кафедры КБ-4 «Интеллектуальные системы информационной безопасности» «Киберполигон» с 09.02.2026 г. по 13.06.2026 г.

Должность на практике (при наличии): студент

1. СОДЕРЖАНИЕ ПРАКТИКИ:

1.1. Изучить требования к оформлению научно-технической документации по практикам; существующие и перспективные методики обеспечения информационной безопасности, используемые для решения задач в сфере будущей профессиональной деятельности; методы и подходы к организации и проведению эксперимента. Определить: актуальные задачи, используемые методики обеспечения информационной безопасности, а также требования к их автоматизации; целевые установки для экспериментального исследования методик информационной безопасности, используемых для решения задач в сфере будущей профессиональной деятельности.

1.2. Практически выполнить: по согласованию с руководителем практики определить тему НИР. Исследовать предметную область для выбранной темы. Оформить отчет в соответствии с требованиями ГОСТ.

1.3. Ознакомиться: с перспективными технологиями, методами и подходами к обеспечению информационной безопасности, программными и программно-аппаратными интерфейсами, обеспечивающими информационное взаимодействие, существующими и перспективными аналогичными решениями; нормативно-правовыми актами по разработке и представлению моделей.

2. ДОПОЛНИТЕЛЬНОЕ ЗАДАНИЕ: написать статью по теме исследования, оформить презентационный материал, выступить на конференции.

3. ОРГАНИЗАЦИОННО-МЕТОДИЧЕСКИЕ УКАЗАНИЯ: в процессе практики рекомендуется использовать периодические издания и отраслевую литературу годом издания не старше 5 лет.

Руководитель практики от кафедры

« ____ » _____ 2026 г.

(_____)

Задание получил:

« ____ » _____ 2026 г.

(_____)

СОГЛАСОВАНО:

Заведующий кафедрой:

« ____ » _____ 2026 г.

(_____)

Подпись

ФИО

Проведенные инструктажи:

Охрана труда:

«__» _____ 2026 г.

Инструктирующий

Подпись

(_____)
Расшифровка, должность

Инструктируемый

Подпись

(_____)
Расшифровка

Техника безопасности:

«__» _____ 2026 г.

Инструктирующий

Подпись

(_____)
Расшифровка, должность

Инструктируемый

Подпись

(_____)
Расшифровка

Пожарная безопасность:

«__» _____ 2026 г.

Инструктирующий

Подпись

(_____)
Расшифровка, должность

Инструктируемый

Подпись

(_____)
Расшифровка

«__» _____ 2026 г.

Инструктирующий

Подпись

(_____)
Расшифровка, должность

Инструктируемый

Подпись

(_____)
Расшифровка

С правилами внутреннего распорядка ознакомлен:

«__» _____ 2026 г.

Подпись

(_____)
Расшифровка



МИНОБРНАУКИ РОССИИ

Федеральное государственное-бюджетное образовательное учреждение
высшего образования

«МИРЭА — Российский технологический университет»

РТУ МИРЭА

**РАБОЧИЙ ГРАФИК ПРОВЕДЕНИЯ
ПРОИЗВОДСТВЕННОЙ ПРАКТИКИ**

(указать вид практики: учебная/производственная)

Студента Шульгина Владислава Андреевича 1 курса группы БМО-01-25 очной формы обучения, обучающегося по направлению подготовки 10.04.01 «Информационная безопасность», специализация «Автоматизация информационно-аналитической деятельности».

Неделя	Сроки выполнения	Этап	Отметка о выполнении
1	09.02.2026-09.03.2026	Подготовительный этап, включающий в себя организационное собрание (Вводная лекция о порядке организации и прохождения производственной практики, инструктаж по технике безопасности)	
2	10.03.2026-13.04.2026	Выполнение задания по практике в соответствии с выданным заданием студента. (Мероприятия по сбору, обработке структурированию материала; выполнение поставленной задачи)	
3	14.04.2026-11.05.2026	Подготовка отчета и презентационного материала по практике (Оформление материалов отчета и презентации в полном соответствии с требованиями на оформление учебных работ студентов)	
4	12.05.2026-13.06.2026	Защита отчета по производственной практике у руководителя практики. Представление отчета по практике к защите	

Содержание практики и планируемые результаты согласованы с руководителем практики от профильной организации.

Руководитель практики от
кафедры

_____ / _____ /

Обучающийся

_____ /Шульгин В.А. /

СОГЛАСОВАНО:

И.о. заведующего кафедрой

_____ / Ноев А.Н. /

РЕФЕРАТ

Исполнитель: студент группы ББМО-01-25 Шульгин Владислав Андреевич.

Руководитель: д.т.н., доцент, профессор кафедры КБ-4 «Интеллектуальные системы информационной безопасности», Козьминых Сергей Игоревич.

Научно-исследовательская работа на тему «Использование технологий машинного обучения для прогнозирования кибератак».

Общее количество страниц: 19.

Работа включает в себя 5 рисунков, 2 таблицы.

Список источников информации включает 18 позиций.

Ключевые слова: КИБЕРАТАКА, МАШИННОЕ ОБУЧЕНИЕ, ПРЕДИКТИВНАЯ АНАЛИТИКА, ИНФОРМАЦИОННАЯ БЕЗОПАСНОСТЬ, ВРЕМЕННОЙ РЯД, ОБНАРУЖЕНИЕ ВТОРЖЕНИЙ, НЕЙРОННЫЕ СЕТИ.

СОДЕРЖАНИЕ

Введение.....	6
1 ИССЛЕДОВАТЕЛЬСКИЙ РАЗДЕЛ.....	7
1.1 Обзор существующих точек зрения на проблему.....	7
1.2 Прогнозирование на примере распределенной атаки типа «отказ в обслуживании»	7
1.3 Прогнозирование на примере многовекторной АРТ-атаки.....	8
1.4 Технологии машинного обучения, с учетом их использования в ИБ	8
1.5 Критерии эффективности прогнозирования атак – описать кто прогнозирует эти атаки (LLM и тд.)	11
2 АНАЛИТИЧЕСКИЙ РАЗДЕЛ.....	13
2.1 Схема архитектуры гибридной системы прогнозирования	13
2.2 Рассуждения на тему.....	15
2.3 Предполагаемые дальнейшие исследования	16
Заключение.....	17
Список использованных источников.....	18

ВВЕДЕНИЕ

Разновидности киберугроз сегодня характеризуются не просто линейным, а экспоненциальным ростом количества инцидентов, что сопровождается качественным скачком в уровне сложности реализуемых атак. Традиционные средства защиты, такие как антивирусное ПО и системы обнаружения вторжений, базирующиеся на жестких правилах и сигнатурном анализе, демонстрируют критическую потерю эффективности [1]. Основная проблема заключается в их реактивной природе: они способны распознать угрозу лишь после того, как она уже проявила себя в системе или была занесена в глобальные базы данных сигнатур.

В то же время киберпреступные группировки активно автоматизируют свои действия, внедряя в арсенал атак самомодифицирующийся полиморфный код и передовые методы социальной инженерии, усиленные генеративным искусственным интеллектом. Это делает любые классические меры защиты заведомо запаздывающими, оставляя «окно уязвимости» открытым для нанесения непоправимого ущерба. В этих условиях стратегически приоритетной становится смена парадигмы обеспечения безопасности: переход от пассивного реагирования на свершившийся факт к активному предвидению. Возникает острая необходимость в проектировании интеллектуальных систем, способных не только констатировать факт глубокого проникновения, но и заблаговременно прогнозировать вероятность и вектор атак еще на этапе их подготовки.

В современной научной литературе тема прогнозирования кибератак с использованием технологий машинного обучения (МО) находится в стадии активного становления и концептуального поиска [2]. На сегодняшний день значительный пласт академических исследований посвящен прикладному применению МО в рамках систем обнаружения и предотвращения вторжений (IDS/IPS), где алгоритмы в реальном времени классифицируют сетевой трафик как легитимный или вредоносный [3]. Однако наблюдается явный дефицит работ, фокусирующихся именно на глубокой предиктивной аналитике. К числу слабоизученных аспектов относятся долгосрочное предсказание временных рядов атак и оценка векторов будущих угроз на основе косвенных признаков.

Большинство существующих теоретических разработок остаются фрагментарными: они успешно решают узкие задачи классификации, но зачастую не учитывают специфику адаптивного поведения атакующих, способных обходить обученные модели с помощью состязательных атак. Для реализации перехода от общего описания ландшафта угроз к конкретике исследования необходимо провести детальный анализ алгоритмической базы и четко определить вектор работы, направленный на минимизацию неопределенности в вопросах кибербезопасности.

1 ИССЛЕДОВАТЕЛЬСКИЙ РАЗДЕЛ

1.1 Обзор существующих точек зрения на проблему

Анализ предметной области показывает разделение исследовательских подходов на несколько направлений. Первое направление базируется на анализе временных рядов. Предлагается использовать рекуррентные нейронные сети (LSTM) и модели Transformer для прогнозирования интенсивности атак на основе исторических данных сетевых датчиков [12]. Второе направление концентрируется на анализе текстовой информации из открытых источников (OSINT), форумов даркнета и отчетов по уязвимостям (CVE). Здесь применяются методы обработки естественного языка (NLP) для выявления зарождающихся угроз. Третья точка зрения, представленная в работах по кибербезопасности крупных вендоров, делает акцент на моделях, имитирующих поведение атакующего (MITRE ATT&CK как база знаний) [6].

Ситуация в отрасли такова, что на рынке преобладают SIEM и SOAR системы с элементами корреляции, однако их прогностическая мощность ограничена [4]. Научное сообщество все чаще склоняется к мнению, что гибридные модели, сочетающие анализ сетевой телеметрии и разведку угроз (Threat Intelligence), имеют наибольший потенциал, но проблема сбора качественных размеченных данных для обучения таких моделей остается нерешенной.

1.2 Прогнозирование на примере распределенной атаки типа «отказ в обслуживании»

Чтобы говорить о прогнозировании в области доступности ресурсов, необходимо понимать динамику развертывания многовекторной DDoS-атаки. Современные атаки уровня приложения развиваются от пристрелочного сканирования уязвимых API и формирования бот-сети до постепенного наращивания легитимных на вид запросов, направленных на исчерпание ресурсов базы данных или оперативной памяти сервера. Прогнозирование в этом сценарии — это идентификация признаков подготовки к деградации сервиса. Система анализирует латентные маркеры: специфический TTL пакетов, аномальное распределение географии входящего трафика или рост числа

незавершенных ТСП-соединений. Задача прогностической модели — с высокой точностью определить точку пересечения графика нагрузки с предельной пропускной способностью инфраструктуры и предсказать, какой именно программный компонент (балансировщик, СУБД или веб-сервер) станет «узким местом», прежде чем сервис уйдет в офлайн.

1.3 Прогнозирование на примере многовекторной АРТ-атаки

Чтобы говорить о прогнозировании, необходимо четко определить структуру самой угрозы. Рассмотрим целевую атаку (Advanced Persistent Threat — АРТ). В отличие от массового заражения, АРТ представляет собой растянутый во времени процесс (Kill Chain), состоящий из этапов: разведка, первоначальный доступ, закрепление, горизонтальное перемещение (Lateral Movement) и эксфильтрация данных. Прогнозирование в данном контексте — это способность системы зафиксировать ранние, латентные признаки активности (например, аномальное сканирование портов или фишинговую рассылку) и с высокой вероятностью предсказать, какой узел инфраструктуры станет следующей целью для горизонтального перемещения и какие техники (TTPs) будут применены злоумышленником на шаге $t + 1$.

Разнообразие подходов диктует необходимость внедрения строгих математических критериев для оценки качества работы прогностических систем.

1.4 Технологии машинного обучения, с учетом их использования в ИБ

В контексте прогнозирования этапов АРТ-атаки, выбор технологий зависит от анализируемых параметров, представленных в Таблице 1.1.

Таблица 1.1 — Технологии машинного обучения, с учетом их использования в ИБ

Категория МО	Алгоритм МО
Обучение с учителем	Логистическая регрессия, метод опорных векторов (svm) и деревья решений используются для простых задач бинарной классификации [6]
	Случайный лес (Random Forest) и Градиентный бустинг (xgboost, catboost, lightgbm) используются для задач с табличными данными. Они эффективны в системах обнаружения вторжений (IDS/IPS) для анализа логов и сетевого трафика. Эти методы

	позволяют оценивать важность каждого признака, что критично для понимания решений аналитиком ИБ Применение к АРТ: Бустинговые алгоритмы анализируют ключевые параметры (IP-адреса источника/назначения, порты, объем переданных байт, флаги TCP) для классификации трафика как этапа «Эксфильтрация»
Обнаружение аномалий	Кластеризация (k-means, dbscan) применяется при сегментации сетевого трафика для выявления ботнетов или группировка вредоносного по по схожему поведению Изолирующий лес (Isolation Forest) и One-Class SVM задействуются как специализированные алгоритмы для поиска выбросов [3]. Эффективны для выявления инсайдерских угроз или работы «нулевого дня» Применение к АРТ: Поиск отклонений во времени авторизации пользователей (Time-based anomalies), что сигнализирует о компрометации учетной записи
Анализ последовательностей и времени	Рекуррентные нейросети (rnn, lstm, gru) нужны для анализа временных рядов событий безопасности. Они позволяют прогнозировать следующий шаг атакующего на основе последовательности предыдущих действий Трансформеры эффективны для анализа длинных последовательностей системных вызовов (syscalls) для обнаружения сложных полиморфных атак Применение к АРТ: LSTM-сеть принимает временной ряд журналов событий Windows (Event ids 4624, 4688) и предсказывает вероятность запуска вредоносного скрипта powershell на соседнем хосте в течение следующих 10 минут
Анализ текста и графики	NLP (Трансформеры типа BERT) применяются для анализа даркнет-форумов и Telegram-каналов для раннего обнаружения обсуждения новых уязвимостей или продажи эксплойтов. Также используется для анализа фишинговых писем [15]
Имитация атак	Q-learning и глубокие q-сети (dqn) используются для создания автономных «красных команд» (red teaming). Агент обучается взаимодействовать с инфраструктурой, чтобы найти самый эффективный и незаметный путь проникновения. Это помогает предсказывать траектории реальных хакеров [14]

В качестве примера, рассмотрим Random Forest (Случайный лес). Это ансамблевый метод, который строит сильную модель через усреднение ответов множества слабых моделей (деревьев решений). Его работа базируется на двух ключевых концепциях: Бэггинг и Метод случайных подпространств.

1. Построение выборки.

Для каждого из B деревьев в лесу создается своя обучающая подвыборка. Если исходный набор данных X содержит N объектов, то для каждого дерева $b \in \{1, \dots, B\}$ генерируется выборка X_b путем случайного выбора с возвращением.

Это означает, что $\sim 63.2\%$ объектов попадут в выборку, а остальные останутся «вне выборки».

2. Математика ветвления.

В каждом узле дерева алгоритм ищет такое разбиение данных на две группы (R_1 и R_2), которое минимизирует «хаос». Для задач классификации чаще всего используется индекс Джини по Формуле 1.1:

$$G = \sum_{k=1}^K p_k(1 - p_k) = 1 - \sum_{k=1}^K p_k^2, \quad (1.1)$$

где p_k — доля объектов класса k в узле.

В Random Forest при поиске лучшего разбиения алгоритм выбирает не из всех M признаков, а из случайного подмножества $m = \sqrt{M}$. Это «декоррелирует» деревья, делая их разными.

3. Агрегация.

Итоговый прогноз модели $\hat{f}$ получается путем объединения результатов всех построенных деревьев $T_b(x)$.

Для регрессии (среднее арифметическое) по Формуле 1.2:

$$\hat{f}(x) = \frac{1}{B} \sum_{b=1}^B T_b(x) \quad (1.2)$$

Для классификации (голосование по большинству) по Формуле 1.3:

$$\hat{C}(x) = \text{mode}\{\hat{C}_1(x), \hat{C}_2(x), \dots, \hat{C}_B(x)\} \quad (1.3)$$

На основе всего вышеописанного [7, 9], составим Таблицу 1.2 классификации технологий машинного обучения в задачах обеспечения информационной безопасности.

Таблица 1.2 — Классификация технологий машинного обучения в задачах обеспечения информационной безопасности

Категория МО	Конкретные алгоритмы	Область применения в ИБ	Ключевые параметры и признаки
Обучение с учителем (Supervised)	Логистическая регрессия, SVM, Деревья решений	Бинарная классификация простых угроз	Табличные данные, флаги сетевых пакетов
Ансамблевые методы	Random Forest, XGBoost, CatBoost, LightGBM	Анализ логов, работа в системах IDS/IPS	IP-адреса, порты, объем трафика, важность признаков
Обучение без учителя	k-means, DBSCAN	Сегментация трафика, поиск ботнетов и схожего ВПО	Поведенческие паттерны, топология соединений

Поиск аномалий	Isolation Forest, One-Class SVM	Выявление инсайдеров и атак «нулевого дня»	Выбросы в статистике активности, аномальное время доступа
Анализ последовательностей	RNN, LSTM, GRU	Прогноз следующего шага атаки, анализ временных рядов	Последовательности событий безопасности во времени
Глубокое обучение (Deep Learning)	Сверточные нейросети (CNN)	Анализ вредоносного ПО в виде изображений, стеганография	Бинарный код как визуальный образ
Обработка текста (NLP)	Трансформеры (BERT), Transformer models	Анализ даркнета, фишинга, системных вызовов (syscalls)	Тексты сообщений, длинные цепочки системных команд

Этот структурированный перечень позволяет наглядно сопоставить математический аппарат с конкретными задачами предиктивной аналитики. Выбор конкретных моделей напрямую зависит от того, какие подходы к анализу данных превалируют в современной научной среде.

1.5 Критерии эффективности прогнозирования атак – описать кто прогнозирует эти атаки (LLM и тд.)

Для оценки прогностических моделей необходимо использовать как базовые, так и специфические метрики с учетом временного фактора предсказания [8].

Пусть TP (True Positive) — верно предсказанные атаки, FP (False Positive) — ложные срабатывания, TN (True Negative) — верно определенный легитимный трафик, FN (False Negative) — пропущенные атаки.

Тогда доля верных ответов (*Accuracy*) вычисляется по Формуле 1.4:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (1.4)$$

Precision показывает, сколько из предсказанных атак были реальными (минимизация ложных тревог). Рассчитывается по Формуле 1.5:

$$Precision = \frac{TP}{TP + FP} \quad (1.5)$$

Recall (TPR) показывает, сколько реальных атак модель смогла предсказать (минимизация пропусков). Рассчитывается по Формуле 1.6:

$$Recall = \frac{TP}{TP + FN} \quad (1.6)$$

F1 представляет из себя гармоническое среднее между *Precision* (5) и *Recall* (6). Используется чаще всего, так как ищет баланс между пропуском атаки и ложным срабатыванием. Рассчитывается по Формуле 1.7:

$$F1 = \frac{Precision \cdot Recall}{Precision + Recall} \quad (1.7)$$

AUC-ROC показывает способность модели ранжировать события. Зависит от соотношения *TPR* (True Positive Rate) и *FPR* (False Positive Rate), которые рассчитываются по Формулам 1.8, 1.9:

$$TPR = \frac{TP}{TP + FN} \quad (1.8)$$

$$FPR = \frac{FP}{FP + TN} \quad (1.9)$$

Теперь мы можем приступить к описанию специфических метрик для ИБ и прогнозирования.

TTR (Time to Respond / Time to Predict) показывает насколько раньше (в минутах/часах) модель предупредила об атаке по сравнению с традиционными средствами защиты или моментом реального ущерба. Математически выражается по Формуле 1.10:

$$\Delta T = t_{attack} - t_{predict}, \quad (1.10)$$

где ΔT должно быть максимизировано,

t_{attack} — время атаки,

$t_{predict}$ — время предсказания.

TPR (8) при низком *FPR* (9) критично для ИБ, так как важно ловить 90% атак при 0.1% ложных срабатываний. Оценивается значение функции ROC при $FPR < \alpha$ (например, $\alpha = 0.001$).

Точность вектора атаки демонстрирует правильно ли модель предсказала как именно атакуют (какую уязвимость используют), а не просто факт угрозы [7, 9].

Наличие формальных метрик позволяет перейти к критическому анализу ограничений текущих методов и поиску новых путей развития.

2 АНАЛИТИЧЕСКИЙ РАЗДЕЛ

2.1 Схема архитектуры гибридной системы прогнозирования

Для практической реализации описанных подходов и интеграции различных методов машинного обучения предлагается концептуальная архитектура системы. Данное решение основывается на модульном принципе, где каждый уровень отвечает за определенный этап обработки информации: от первичного сбора сырой телеметрии до генерации вероятностного прогноза с привязкой к конкретным техникам по классификации MITRE ATT&CK [10].

Ниже представлена структурная схема, иллюстрирующая взаимодействие компонентов внутри гибридной модели на Рисунках 2.1-2.5.



Рисунок 2.1 — Схема взаимодействия компонентов внутри гибридной модели, слой 1



Рисунок 2.2 — Схема взаимодействия компонентов внутри гибридной модели, слой 2




Рисунок 2.3 — Схема взаимодействия компонентов внутри гибридной модели, слой 3



Рисунок 2.4 — Схема взаимодействия компонентов внутри гибридной модели, слой 4




Рисунок 2.5 — Схема взаимодействия компонентов внутри гибридной модели, слой 5

Архитектуру предлагаемой прогностической системы можно представить в виде следующих взаимосвязанных логических слоев:

1. Слой сбора данных (Data Ingestion Layer):
 - сетевая телеметрия (NetFlow, PCAP);

- журналы событий хостов (Sysmon, Windows Event Logs);
- внешний контекст (Threat Intelligence фиды, парсинг CVE).
- 2. Слой предварительной обработки (Preprocessing & Feature Engineering):
 - нормализация данных, извлечение признаков (time-windows, частотность событий);
 - векторизация текстовых артефактов (NLP-модели).
- 3. Вычислительное ядро (Ensemble Machine Learning Core):
 - модуль 1 (Обнаружение аномалий): Изолирующий лес (Isolation Forest) — выявление отклонений от базового профиля (Baseline);
 - модуль 2 (Анализ цепочек): Графовая нейронная сеть (GNN) или LSTM — сопоставление аномалий с паттернами графа MITRE ATT&CK [11].
- 4. Слой прогнозирования (Prediction Engine):
 - формирование вероятностного вектора атаки на момент времени $t + \Delta t$;
 - расчет индекса уверенности (Confidence Score).
- 5. Слой реагирования (Output / SOAR Integration):
 - передача алерта аналитикам (TTR метрика) с указанием узла сети и прогнозируемой техники атаки.

Предложенная архитектура позволяет не только автоматизировать процесс выявления инцидентов, но и за счет использования графовых и рекуррентных сетей формировать предиктивный контекст, значительно сокращая время реагирования (TTR). Описанная технологическая связка является фундаментом для более глубокого анализа специфики антагонистического противоборства в цифровой среде.

Теоретическое обоснование выбранной гибридной модели и анализ сложностей, возникающих при её внедрении, закладывают основу для дальнейших критических изысканий.

2.2 Рассуждения на тему

Представляется, что ключевым недостатком текущих исследований является попытка напрямую перенести методы МО из областей с более статичными данными (например, предсказание погоды или цен на акции) в киберпространство. Кибератаки — это антагонистический процесс: злоумышленник адаптируется к действиям защиты, намеренно создавая шум [5] и искажая статистические закономерности.

В связи с этим, перспективным видится не просто использование МО как "черного ящика" для предсказания, а интеграция экспертных знаний о тактиках противника в архитектуру моделей. Например, целесообразно разрабатывать ансамблевые методы, где один алгоритм отвечает за обнаружение аномалий в трафике (выявление этапа разведки или эксплуатации), а другой — анализирует цепочки событий на соответствие паттернам известных кампаний (используя графовые нейронные сети).

Кроме того, важно сместить фокус с прогнозирования факта атаки на прогнозирование наиболее вероятного ее вектора в конкретной инфраструктуре в краткосрочной перспективе. Это требует создания цифровых двойников сети, где модели МО могли бы воспроизводить возможные сценарии действий нарушителя. Дополнительной проблемой выступает "отравление данных" (Adversarial Machine Learning) — сценарии, при которых хакеры целенаправленно отправляют искаженный легитимный трафик, чтобы сместить границу принятия решений у ML-модели, что требует регулярного аудита самих алгоритмов защиты [2, 13].

Теоретическое обоснование гибридного подхода закладывает фундамент для проведения серии практических экспериментов.

2.3 Предполагаемые дальнейшие исследования

Дальнейшие исследования предполагается направить на решение проблемы дисбаланса классов (атак мало по сравнению с "нормальным" трафиком) и нестационарности данных (концептуальный дрейф) [17]. Планируется разработка прототипа модели на основе градиентного бустинга (например, CatBoost) в сочетании с LSTM-сетями для учета временной зависимости [18]. Особое внимание будет уделено отбору признаков (feature engineering), характеризующих состояние защищаемой системы, и верификации модели на реальных датасетах (например, CICIDS2017 или данных корпоративной инфраструктуры в режиме эмуляции).

В качестве расширения планируется исследовать подходы федеративного обучения (Federated Learning) [16]. Это позволит агрегировать опыт различных компаний по выявлению новых TTPs злоумышленников без прямой передачи конфиденциальных журналов событий в единый центр, решая тем самым проблему нехватки качественных размеченных данных для предиктивной аналитики. Также необходимо провести стресс-тестирование разработанных архитектур на устойчивость к состязательным атакам на саму модель МО.

Резюмируя намеченные шаги, можно сформулировать итоговое видение проблемы, выносимое на защиту.

ЗАКЛЮЧЕНИЕ

В ходе проведенного исследования был выполнен комплексный анализ современного состояния и перспектив применения технологий интеллектуального анализа данных в сфере обеспечения кибербезопасности. Полученные результаты позволяют сделать обоснованный вывод о том, что, несмотря на достигнутые многообещающие успехи в области классического обнаружения атак, задача их долгосрочного и краткосрочного прогнозирования с использованием методов машинного обучения все еще сталкивается с серьезными фундаментальными вызовами. Существующие системы в большинстве своем остаются реактивными, что в условиях стремительной интеллектуализации киберугроз требует принципиально иного, проактивного подхода к моделированию сложного поведения потенциального противника.

Традиционные алгоритмы обучения с учителем зачастую оказываются неспособны адаптироваться к быстро меняющимся стратегиям злоумышленников, которые намеренно модифицируют свои действия для обхода защитных механизмов. Таким образом, простое масштабирование вычислительных мощностей или использование более глубоких нейронных сетей без изменения самой логики анализа не приносит ожидаемого прироста в надежности предсказаний.


Научная проблема, выносимая на защиту и требующая последующего концептуального решения, заключается в необходимости преодоления разрыва между сухим статистическим анализом трафика и семантическим пониманием действий хакера. Она формулируется следующим образом: повышение точности и достоверности краткосрочного прогнозирования кибератак в условиях высокой априорной неопределенности. Для этого требуется отказ от изолированных моделей в пользу разработки сложных гибридных архитектур машинного обучения. Такие системы должны не только обрабатывать сырую сетевую телеметрию, но и интегрировать в себя контекстную информацию о специфических тактиках, техниках и процедурах (TTP) нарушителей.

В качестве перспективного вектора развития предлагается использование базы знаний MITRE ATT&CK [6] как фундамента для обогащения данных обучения. Это позволит модели «понимать» не просто аномальные пакеты данных, а логическую последовательность этапов кибератаки (Kill Chain). Кроме того, предлагаемое решение должно учитывать антагонистический характер современного киберпространства, внедряя элементы теоретико-игрового моделирования и методы состязательного обучения (adversarial learning). Только такой комплексный междисциплинарный подход позволит создать системы защиты нового поколения, способные превентивно нейтрализовать угрозы до момента нанесения ими фактического ущерба инфраструктуре.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Бойченко, О. В.; Светлов, С. А. Применение искусственного интеллекта для защиты данных // Теория и практика экономики и предпринимательства: Труды XXI Междунар. науч.-практ. конф. Симферополь, 2024. С. 281–282.
2. Намиот, Д. Е.; Ильюшин, Е. А.; Чижов, И. В. Искусственный интеллект и кибербезопасность // International Journal of Open Information Technologies. 2022. Т. 10, № 9. С. 135–147.
3. Ляпунцова, Е. В.; Арм, А. А. С. Использование искусственного интеллекта для повышения сетевой безопасности: стратегии обнаружения аномалий и перспективы внедрения // Известия Тульского государственного университета. Технические науки. 2024. № 3. С. 131–136. DOI: 10.24412/2071-6168-2024-3-131-132.
4. Кузнецов, С. В.; Пелехов, Д. А.; Новлянский, В. В. Роль искусственного интеллекта в обнаружении и предотвращении кибератак // Наука и реальность. 2024. № 2 (18). С. 57–60.
5. Минбалеев, А. В. Проблемы использования искусственного интеллекта в противодействии киберпреступности // Вестник Южно-Уральского государственного университета. Сер. Право. 2020. Т. 20, № 4. С. 116–120. DOI: 10.14529/law200420.
6. Алпеев, Е. В.; Стадник, А. Н.; Скрыль, С. В. Методика прогнозирования компьютерных атак на основе определения весов атрибутов компьютерной атаки с применением метода деревьев решений // Научные труды КубГТУ. 2021. № 6. С. 82–92.
7. Rodriguez, M.; Patel, R. Hybrid machine learning and deep neural network framework for cyber attack prediction in network infrastructures // IEEE Access. 2024. Vol. 12. P. 87654–87668.
8. Ankalaki, S.; et al. Cyber Attack Prediction: From Traditional Machine Learning to Generative Artificial Intelligence // IEEE Xplore. 2025. URL: <https://www.google.com/search?q=https://ieeexplore.ieee.org/document/10909100> (дата обращения: 07.04.2026).
9. Torres, M.; Banerjee, A. Cyber threat forecasting using hybrid deep learning and anomaly detection techniques // Knowledge-Based Systems. 2024. Vol. 280. Art. 110912.
10. Diaf, A.; et al. Beyond Detection: GPT-driven prediction and LSTM-based threat classification in hybrid feedback loops // Emergent Mind / CTI Research. 2024. URL: <https://www.emergentmind.com/topics/llm-driven-cyber-threat-prediction> (дата обращения: 07.04.2026).

11. Абрамов, И. В. Применение графовых нейронных сетей для анализа горизонтального перемещения в корпоративных сетях / И. В. Абрамов // Вопросы кибербезопасности. – 2025. – № 1 (53). – С. 42-50.
12. Гаврилов, А. Д. Прогнозирование временных рядов сетевой активности с использованием архитектуры Transformer / А. Д. Гаврилов, Е. М. Смирнов // Информационные технологии и вычислительные системы. – 2023. – № 4. – С. 15-27.
13. Карпов, М. А. Состязательные атаки на модели машинного обучения в системах обнаружения вторжений: методы защиты / М. А. Карпов // Системы высокой доступности. – 2024. – Т. 20, № 2. – С. 33-45.
14. Лебедев, В. В. Автоматизация Red Teaming на основе глубокого обучения с подкреплением / В. В. Лебедев // Кибернетика и программирование. – 2024. – № 5. – С. 88-102.
15. Никитин, С. П. Использование методов NLP для анализа Threat Intelligence данных из даркнет-площадок / С. П. Никитин // Вестник компьютерных и информационных технологий. – 2022. – № 11. – С. 20-29.
16. Соколов, Д. И. Федеративное обучение как метод обеспечения конфиденциальности при обмене данными об угрозах / Д. И. Соколов, А. В. Федоров // Безопасность информационных технологий. – 2025. – Т. 32, № 2. – С. 55-68.
17. Ушаков, К. Г. Оценка прогностической точности моделей МО в условиях концептуального дрейфа сетевого трафика / К. Г. Ушаков // Программная инженерия. – 2023. – № 8. – С. 392-401.
18. Чернов, А. С. Комбинирование ансамблевых методов и LSTM-сетей для предиктивного анализа АРТ-атак / А. С. Чернов // Радиоэлектроника. Информатика. Управление. – 2021. – № 3. – С. 112-124.



Настоящим подтверждается, что

Владислав Андреевич

принял(а) участие

в работе Секции

«Искусственный интеллект в кибербезопасности: технологии атаки и защиты»

**У ЕЖЕГОДНОЙ НАЦИОНАЛЬНОЙ
НАУЧНО-ПРАКТИЧЕСКОЙ КОНФЕРЕНЦИИ
«КИБЕРБЕЗОПАСНОСТЬ: ТЕХНИЧЕСКИЕ И ПРАВОВЫЕ
АСПЕКТЫ ЗАЩИТЫ ИНФОРМАЦИИ»,
ПОСВЯЩЕННОЙ 90-летию МГУПИ**

(23-29 апреля 2026 г.)

Проректор



И.Е. Рогов

2026 год