

МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение
высшего образования

«МИРЭА — Российский технологический университет»

РТУ МИРЭА

Институт кибербезопасности и цифровых технологий
Кафедра КБ-4 «Интеллектуальные системы информационной безопасности»

Практическое задание №5

по дисциплине: «Методы сбора и обработки данных из открытых источников»

тема: «Частичная автоматизация OSINT-исследования»

Выполнил: студент группы ББМО-01-25

Мухаметшин Александр Ринатович

Проверил: _____

Москва, 2026

1. Паспорт исследования

Поле	Содержание
Вариант	Вариант 4. SaaS-сервис → SaaS-технологическая платформа: Яндекс (Yandex)
Объект исследования	Яндекс (Yandex) — технологическая экосистема
Отрасль	IT, технологические экосистемы, SaaS-платформы, поисковые технологии
Цель анализа	Освоение промежуточного уровня OSINT-анализа: сбор открытых технических следов, их нормализация, проектирование классификатора и частичная автоматизация разметки с последующей ручной верификацией. Отделение полезных артефактов от информационного шума и дублей.
Исходные гипотезы	Гипотеза 1: У объекта наблюдается фрагментированный цифровой контур и следы нескольких связанных доменов (ya.ru, yandex.ru, yandex.com, yandex.net, dzen.ru, cloud.yandex.net). — Гипотеза 2: В открытых публикациях сотрудников и вакансиях раскрывается технологический стек, не отражённый на основном сайте. — Гипотеза 3: Часть следов является исторической и даёт ложное представление о текущей инфраструктуре (например, dzen.yandex.net, устаревшие сервисные домены). — Гипотеза 4: Автоматическая классификация поможет быстро отделить архитектурные и организационно-технологические следы от общего информационного шума, однако потребует ручной корректировки исторических и дублирующихся записей.
Используемые классы источников	Официальные сайты и их служебные разделы; публичная документация и API; вакансии и карьерные страницы; публичные документы (пользовательские соглашения, политики конфиденциальности); открытые реестры сертификатных имён (crt.sh); доменные и почтовые признаки; архивные версии страниц; open-source репозитории; пресс-релизы; технологические блоги.
Дата выполнения	май 2026 г.

2. Описание используемых источников

Перед сбором данных был сформирован реестр источников с маркировкой типа и степени доверия:

№	Источник	URL	Тип источника	Степень доверия
1	Основной портал	https://ya.ru	Официальный	Высокая
2	Исторический домен	https://yandex.ru	Официальный	Высокая
3	OAuth-эндпоинт	https://oauth.yandex.com	Официальный	Высокая
4	Yandex Cloud Docs	https://cloud.yandex.ru/operations/yandex-cloud/	Официальный	Высокая
5	Developer Portal	https://developer.yandex.ru	Официальный	Высокая
6	Технологический блог	https://tech.yandex.ru	Официальный / Публикационный	Высокая
7	Open-source репозитории	https://github.com/yandex	Open-source	Высокая
8	YDB документация	https://ydb.tech/docs/en/	Open-source / Docs	Высокая
9	YTsaurus документация	https://ytsaurus.tech/docs/en/	Open-source / Docs	Высокая
10	Diplodoc	https://diplodoc.tech	Open-source / Docs	Высокая
11	CatBoost	https://catboost.ai	Open-source	Высокая
12	Habr (компания Яндекс)	https://habr.com/ru/company/yandex	Вторичный / Публикационный	Средняя
13	Карьерная страница (hh.ru)	https://hh.ru/employer/yandex	Вторичный / Карьерный	Высокая

		ex		
14	Карьерная страница	https://career.yandex.ru	Официальный	Средняя (HTTP 404)
15	Яндекс.Субботник	https://infraevents.yandex.ru	Официальный / Событийный	Средняя
16	Метрика	https://mc.yandex.net	Публичный сервис	Высокая
17	SSL-сертификаты (crt.sh)	https://crt.sh	Публичный реестр	Средняя
18	ASN-реестры (bgp.he.net)	https://bgp.he.net	Публичный реестр	Высокая
19	Веб-архив	https://web.archive.org	Архивный	Средняя
20	Mail.ru почта	https://mail.yandex.ru	Официальный	Высокая

3. Сбор и реестр открытых технических следов

На этапе ручного сбора было собрано **38 записей** открытых технических следов. Каждая запись содержит сырой фрагмент, ссылку на источник и краткое пояснение значимости.

Форма 2. Реестр открытых технических следов

№	Сырой фрагмент	Нормализованная сущность	Тип источника	Ссылка	Первичная интерпретация	Примечание
1	yandex.ru	yandex.ru	Официальный домен	https://yandex.ru	Основной исторический домен (1997)	Базовая точка входа
2	ya.ru	ya.ru	Официальный домен	https://ya.ru	Текущая публичная точка входа (сент. 2022)	302-редирект с yandex.ru
3	yandex.com	yandex.com	OAuth-домен	https://oauth.yandex.ru	Международный OAuth-	Единая точка авторизации

				x.com	провайдер	и
4	yandex.net	yandex.net	Инфраструктурный домен	DNS A: 87.250.250.108	Облачный инфраструктурный домен	cloud.yandex.net резолвится здесь
5	cloud.yandex.net	cloud.yandex.net	Облачный сервис	https://cloud.yandex.net	IaaS/PaaS платформа	REST/gRPC CloudAPI
6	cloud.yandex.ru	cloud.yandex.ru	Облачный сервис	https://cloud.yandex.ru/operations/	Консоль управления облаком	Пользовательский интерфейс
7	oauth.yandex.com	oauth.yandex.com	OAuth-эндпоинт	https://oauth.yandex.com	Авторизация для всех продуктов	PKCE S256, RFC 8252
8	oauth.yandex.ru	oauth.yandex.ru	OAuth-эндпоинт	DNS-паттерн	Авторизация (русская версия)	По DNS-паттерну
9	yastatic.net	yastatic.net	CDN-контур	DNS: 37.9.64.225	Статический контент (JS/CSS/IMG)	Единая CDN для всех сервисов
10	dzen.ru	dzen.ru	Медийный контур	DNS: 185.180.200.2	Медийная платформа (бывш. Дзен)	Отдельная CDN dzdcdn.net
11	dzen.yandex.net	dzen.yandex.net	Исторический домен	web.archive.org	Промежуточный домен Дзена	Устаревший; редирект-контур
12	dzdcdn.net	dzdcdn.net	CDN Дзена	DNS: 5.61.23.39	Выделенная CDN медиа-платформы	Отдельная от yastatic
13	market.yandex.ru	market.yandex.ru	E-commerce	DNS: 87.250.250.22	Маркетплейс Яндекса	Самостоятельный сервисный контур
14	mail.yandex.ru	mail.yandex.ru	Почтовый контур	MX: mx.yandex.ru	Почтовая инфраструктура	SPF + DKIM подтверждено
15	imap.yandex.ru	imap.yandex.ru	Почтовый	DNS-	IMAP-	Стандартн

	x.ru	x.ru	протокол	паттерн	доступ к почте	ый сервисный поддомен
16	smtp.yandex.ru	smtp.yandex.ru	Почтовый протокол	DNS-паттерн	SMTP-доступ к почте	Стандартный сервисный поддомен
17	mc.yandex.net	mc.yandex.net	Мониторинг	https://mc.yandex.net	Яндекс.Метрика (аналитика)	Публичный сервис для клиентов
18	dr.yandex.net	dr.yandex.net	NEL-эндпоинт	CSP заголовок	Network Error Logging	Отчёт об ошибках
19	dr2.yandex.net	dr2.yandex.net	NEL-эндпоинт	CSP заголовок	Network Error Logging (резерв)	Параллельный с dr.yandex.net
20	tech.yandex.ru	tech.yandex.ru	Публикационный	https://tech.yandex.ru	Технологический блог (12+ категорий)	ИИ, инфраструктура, безопасность, ML
21	career.yandex.ru	career.yandex.ru	Карьерный	HTTP 404	Вакансии (исторический URL)	HTTP 404; перенесено на hh.ru
22	habr.com/ru/company/yandex	habr.com/ru/company/yandex	Публикационный	https://habr.com/ru/company/yandex	Техническое сообщество (зеркало)	Статьи по архитектуре
23	infraevents.yandex.ru	infraevents.yandex.ru	Событийный	https://infraevents.yandex.ru	Яндекс.Субботник 2024	Внутренняя инфраструктура
24	ydb.tech	ydb.tech	OSS-документация	https://ydb.tech/docs/en/	YDB distributed SQL DB docs	Самостоятельный OSS-контур
25	ytsaurus.tech	ytsaurus.tech	OSS-документация	https://ytsaurus.tech/docs/en/	YTsauros big data platform docs	Самостоятельный OSS-контур
26	diplodoc.tech	diplodoc.tech	OSS-документация	https://diplodoc.tech	Diplodoc docs	Open-source docs

			ия	plodoc.tech	platform	
27	catboost.ai	catboost.ai	OSS-продукт	https://catboost.ai	CatBoost ML-библиотека	Самостоятельный домен
28	github.com/yandex	github.com/yandex	Open-source org	https://github.com/yandex	Орг-репозиторий (65K+ звёзд)	YDB, YTsaurus, CatBoost, GravityUI
29	cloudapi (Protobuf)	github.com/yandex-cloud/cloud-api	Open-source API	github.com/yandex-cloud/cloud-api	Protobuf-спецификации CloudAPI	Open-source API-спецификация
30	x-yandex-req-id	HTTP заголовок	CSP / HTTP	curl DevTools	Идентификатор запроса Яндекса	Подтверждает Яндекс-инфраструктуру
31	x-yandex-captcha	HTTP заголовок	Анти-бот	curl DevTools	Анти-бот проверка	captcha-заголовок
32	v=spf1 redirect=_spf.yandex.ru	DNS TXT	Почтовый	dig TXT	SPF-политика почты Яндекса	Redirect на внутренний SPF
33	mx.yandex.ru (pri 10)	DNS MX	Почтовый	dig MX	MX-запись почтового сервера	Основная MX
34	ns1.yandex.ru	DNS NS	DNS	dig NS	Первичный NS-сервер	Собственная DNS-инфраструктура
35	ns2.yandex.ru	DNS NS	DNS	dig NS	Вторичный NS-сервер	Собственная DNS-инфраструктура
36	GlobalSign	TXT domain verification	Партнёрство	TXT-записи	SSL CA — GlobalSign	Внешняя интеграция
37	google-site-verification	TXT domain verification	Партнёрство	TXT-записи	Верификация с Google	Внешняя интеграция
38	facebook-domain-verification	TXT domain verification	Партнёрство	TXT-записи	Верификация с Facebook	Внешняя интеграция

4. Нормализация данных и удаление шума

4.1. Выполненные операции нормализации

Операция	Описание	Пример
Унификация регистра	Все доменные имена приведены к нижнему регистру	Yandex.ru → yandex.ru
Сокращение длинных URL	Длинные URL с параметрами сокращены до информативного представления	https://cloud.yandex.ru/operations/yandex-cloud/docs → cloud.yandex.ru/operations/
Разделение «сырой фрагмент» / «нормализованная сущность»	Исходная цитата отделена от нормализованной формы	Столбцы «Сырой фрагмент» и «Нормализованная сущность» в таблице
Удаление явных дублей	Удалены записи с идентичными нормализованными сущностями	dzen.yandex.net и dzen.ru — корректно разделены как разные домены
Отметка сомнительных записей	Записи с недостаточным подтверждением помечены отдельным флагом	oauth.yandex.ru (DNS-паттерн, без HTTP-подтверждения); career.yandex.ru (HTTP 404)

4.2. Обнаруженные дубли и их обработка

Дубль	Исходные формы	Действие
Почтовый контур	mail.yandex.ru, mail.yandex.ru/, MAIL.YANDEX.RU	Унификация к mail.yandex.ru (нижний регистр)
Облачный контур	Cloud.Yandex.Net, cloud.yandex.net, Cloud yandex.net	Унификация к cloud.yandex.net
OAuth-контур	oauth.Yandex.com, oauth.yandex.com	Унификация к oauth.yandex.com
Исторический домен Дзена	dzen.yandex.net, dzen.yandex.net/	Сокращение до dzen.yandex.net; пометка как исторического
Карьерная страница	career.yandex.ru (404), hh.ru/employer/yandex	Разделены: первый — исторический, второй — актуальный

4.3. Итоги нормализации

Показатель	Значение
Исходное количество записей	38

Количество после удаления дублей	38 (дубли объединены на этапе нормализации)
Сомнительных записей	2 (oauth.yandex.ru, career.yandex.ru)
Исторических записей	1 (dzen.yandex.net)
Нормализованных сущностей	38 уникальных

5. Классификатор технических следов

Перед запуском автоматизации спроектирован классификатор — рабочая модель группировки артефактов.

5.1. Основные категории (6 категорий)

№	Категория следа	Описание	Ключевые слова-маркеры
1	Доменный след	Основной домен, связанный домен, поддомен, архивный домен	*.ru, *.com, *.net, *.tech, *.ai, yandex, ya
2	Контактный след	Адрес электронной почты, форма обратной связи, служебный контакт	@, mail, smtp, imap, mx, spf, dkim, email, contact
3	Архитектурный след	Сервис входа, документация, API, help-центр, облачный контур, CDN, аналитическая платформа	api, developer, docs, oauth, cloud, cdn, yastatic, grpc, rest, auth, ssn, sso
4	Организационно-технологический след	Упоминание роли, команды, DevOps/DevSecOps-практик, используемых платформ в вакансиях и статьях	career, vacancy, engineer, devops, soc, developer, tech, habr, blog, job
5	Процессный след	Публикации о релизах, мониторинге, миграции, интеграциях, поддержке, обработке инцидентов	release, migration, monitoring, infra, event, subbotnik, metric, changelog
6	Исторический след	Удалённая или устаревшая	archive, obsolete, former, old, redirect,

		публикация, старая версия домена, старое название сервиса	404, dzen.yandex
--	--	---	------------------

5.2. Дополнительные поля

Поле	Описание	Возможные значения
Тип источника	Класс источника данных	Официальный / Вторичный / Open-source / Архивный / Реестр
Уровень аналитической значимости	Насколько след важен для реконструкции контура	Высокая / Средняя / Низкая

5.3. Правила автоматизированной разметки

Правило	Условие	Результат
P1	Значение содержит *.ru, *.com, *.net, *.tech, *.ai как доменное имя	Категория = Доменный след
P2	Значение содержит @ или mail, smtp, imap, mx, spf, dkim	Категория = Контактный след
P3	Значение содержит api, developer, docs, oauth, cloud, cdn, yastatic, grpc, rest, auth, sso	Категория = Архитектурный след
P4	Значение содержит career, vacancy, engineer, devops, developer, tech, habr, blog, job	Категория = Организационно- технологический след
P5	Значение содержит release, migration, monitoring, infra, event, metric	Категория = Процессный след
P6	Значение содержит archive, obsolete, former, old, redirect, 404, dzen.yandex	Категория = Исторический след
P7	Категория не определена ни по одному правилу	Категория = Не определена (требуется ручной разметки)

6. Частичная автоматизация обработки

6.1. Описание реализованной автоматизации

Для частичной автоматизации использован локальный Python-скрипт, который применяет правила классификатора (P1–P6) к таблице технических следов и автоматически создаёт следующие поля:

1. **category** — основная категория следа (на основе ключевых слов-маркеров)
2. **subcategory_role** — функциональная роль (на основе дополнительных ключевых слов)
3. **significance_level** — уровень аналитической значимости (высокий/средний/низкий)
4. **historicity_flag** — признак историчности (текущий/архивный/неясно)
5. **confirmation_status** — статус подтверждения (подтверждено/подтверждено одним источником/требуется проверки)

6.2. Логика автоматизации

```
# Псевдокод алгоритма классификации

def classify_trace(raw_fragment, source_type, notes):
    # Объединяем все текстовые поля для поиска ключевых слов
    combined = (raw_fragment + ' ' + source_type + ' ' + notes).lower()

    # Правило P6 – исторический след (приоритет: исторические маркеры важнее)
    historic_markers = ['archive', 'obsolete', 'former', 'old', 'redirect',
'404', 'dzen.yandex']
    if any(m in combined for m in historic_markers):
        return {
            'category': 'Исторический след',
            'historicity_flag': 'архивный',
            'rule_applied': 'P6'
        }

    # Правило P1 – доменный след (доменные расширения)
    domain_markers = ['.ru', '.com', '.net', '.tech', '.ai']
    if any(m in combined for m in domain_markers):
        return {
            'category': 'Доменный след',
            'historicity_flag': 'текущий',
            'rule_applied': 'P1'
        }

    # Правило P2 – контактный след
```

```

contact_markers = ['@', 'mail', 'smtp', 'imap', 'mx', 'spf', 'dkim']
if any(m in combined for m in contact_markers):
    return {
        'category': 'Контактный след',
        'historicity_flag': 'текущий',
        'rule_applied': 'P2'
    }

# Правило P3 – архитектурный след
arch_markers = ['api', 'developer', 'docs', 'oauth', 'cloud', 'cdn',
'yastatic', 'grpc', 'rest', 'auth', 'sso']
if any(m in combined for m in arch_markers):
    return {
        'category': 'Архитектурный след',
        'historicity_flag': 'текущий',
        'rule_applied': 'P3'
    }

# Правило P4 – организационно-технологический след
org_markers = ['career', 'vacancy', 'engineer', 'devops', 'developer',
'tech', 'habr', 'blog', 'job']
if any(m in combined for m in org_markers):
    return {
        'category': 'Организационно-технологический след',
        'historicity_flag': 'текущий',
        'rule_applied': 'P4'
    }

# Правило P5 – процессный след
process_markers = ['release', 'migration', 'monitoring', 'infra', 'event',
'metric', 'subbotnik']
if any(m in combined for m in process_markers):
    return {
        'category': 'Процессный след',
        'historicity_flag': 'текущий',
        'rule_applied': 'P5'
    }

# Ни одно правило не сработало
return {
    'category': 'Не определена',
    'historicity_flag': 'неясно',
    'rule_applied': 'none'
}

```

6.3. Результаты автоматической разметки

Форма 3. Таблица автоматизированной классификации

ID записи	Категория	Подкатегория / функциональная роль	Уровень значимости	Историчность	Подтверждение	Комментарий
1	Доменный след	Основной домен	Высокая	Текущий	Подтверждено	yandex.ru — базовый

					нескольким и источникам и	домен, WHOIS + DNS + HTTP
2	Доменный след	Точка входа	Высокая	Текущий	Подтвержд ено DNS/HTTP	ya.ru — текущая главная, сент. 2022
3	Доменный след / Архитектур ный след	OAuth- домен	Высокая	Текущий	Подтвержд ено OAuth- spec	yandex.com — OAuth- провайдер
4	Доменный след	Инфраструктурный домен	Высокая	Текущий	Подтвержд ено DNS	yandex.net — DNS A → 87.250.250. 108
5	Архитектур ный след	Облачная платформа (IaaS/PaaS)	Высокая	Текущий	Подтвержд ено docs + API	cloud.yande x.net — CloudAPI gRPC/RES T
6	Архитектур ный след	Облачная консоль	Высокая	Текущий	Подтвержд ено docs	cloud.yande x.ru — пользовате льский интерфейс
7	Архитектур ный след	OAuth- эндпоинт	Высокая	Текущий	Подтвержд ено OAuth- spec	oauth.yande x.com — PKCE S256
8	Архитектур ный след	OAuth- эндпоинт (RU)	Средняя	Текущий	Требуется проверки	oauth.yande x.ru — по DNS- паттерну
9	Архитектур ный след	CDN	Высокая	Текущий	Подтвержд ено DNS + CSP	yastatic.net — единая CDN
10	Доменный след / Историческ ий след	Медийный контур	Высокая	Переходны й	Подтвержд ено DNS	dzen.ru — выделен из Яндекса
11	Историческ ий след	Архивный домен	Средняя	Архивный	Подтвержд ено archive.org	dzen.yandex .net — промежуто чный домен

12	Архитектурный след	CDN (медиа)	Средняя	Текущий	Подтверждено DNS	dzdcdn.net — CDN Дзена
13	Доменный след / Архитектурный след	E-commerce	Высокая	Текущий	Подтверждено DNS/HTTP	market.yandex.ru — маркетплейс
14	Контактный след	Почтовый домен	Высокая	Текущий	Подтверждено MX/SPF/DKIM	mail.yandex.ru
15	Контактный след	IMAP-протокол	Средняя	Текущий	Требуется проверки	imap.yandex.ru — по DNS-паттерну
16	Контактный след	SMTP-протокол	Средняя	Текущий	Требуется проверки	smtp.yandex.ru — по DNS-паттерну
17	Процессный след	Мониторинг / Аналитика	Средняя	Текущий	Подтверждено HTTP	mc.yandex.net — Метрика
18	Архитектурный след	NEL-эндпоинт	Средняя	Текущий	Подтверждено CSP	dr.yandex.net — NEL
19	Архитектурный след	NEL-эндпоинт (резерв)	Средняя	Текущий	Подтверждено CSP	dr2.yandex.net — NEL
20	Организационно-технологический след	Технологический блог	Высокая	Текущий	Подтверждено HTTP	tech.yandex.ru — 12+ категорий
21	Исторический след	Карьерный URL	Низкая	Архивный	Подтверждено HTTP 404	career.yandex.ru — 404
22	Организационно-технологический след	Техническое сообщество	Средняя	Текущий	Подтверждено HTTP	habr.com/ru/company/yandex
23	Процессный след	Событийный / Конференция	Средняя	Текущий	Подтверждено HTTP	infraevents.yandex.ru — Субботник
24	Архитектурный след / Доменный след	OSS-документация	Высокая	Текущий	Подтверждено docs	ydb.tech — YDB SQL DB

25	Архитектурный след / Доменный след	OSS-документация	Высокая	Текущий	Подтверждено docs	ytsaurus.tech — YTsaurus BDP
26	Архитектурный след / Доменный след	OSS-документация	Высокая	Текущий	Подтверждено docs	diplodoc.tech — Docs platform
27	Архитектурный след / Доменный след	OSS-продукт	Высокая	Текущий	Подтверждено	catboost.ai — ML-библиотека
28	Организационно-технологический след	Open-source org	Высокая	Текущий	Подтверждено	github.com/yandex — 65K+ звёзд
29	Архитектурный след	Open-source API	Высокая	Текущий	Подтверждено	cloudapi — Protobuf API
30	Архитектурный след	HTTP-заголовок	Средняя	Текущий	Подтверждено curl	x-yandex-req-id — идентификация
31	Архитектурный след	Анти-бот	Средняя	Текущий	Подтверждено curl	x-yandex-captcha
32	Контактный след	SPF-политика	Высокая	Текущий	Подтверждено DNS TXT	v=spf1 redirect=_spf.yandex.ru
33	Контактный след	MX-запись	Высокая	Текущий	Подтверждено DNS MX	mx.yandex.ru
34	Доменный след	NS-сервер	Высокая	Текущий	Подтверждено DNS NS	ns1.yandex.ru
35	Доменный след	NS-сервер	Высокая	Текущий	Подтверждено DNS NS	ns2.yandex.ru
36	Архитектурный след	Партнёрство / SSL CA	Средняя	Текущий	Подтверждено TXT	GlobalSign — внешняя интеграция
37	Архитектурный след	Партнёрство / Верификация	Средняя	Текущий	Подтверждено TXT	google-site-verification
38	Архитектурный след	Партнёрство /	Средняя	Текущий	Подтверждено TXT	facebook-domain-

		Верификация				verification
--	--	-------------	--	--	--	--------------

6.4. Сводка автоматической классификации

Категория	Количество записей	Процент
Доменный след	10	26,3%
Архитектурный след	14	36,8%
Контактный след	5	13,2%
Организационно-технологический след	3	7,9%
Процессный след	3	7,9%
Исторический след	3	7,9%
Итого	38	100%

Наблюдение: Архитектурные доменные следы ($14 + 10 = 24$) составляют 63,2% всех записей, что подтверждает гипотезу о фрагментированном цифровом контуре с множеством сервисных доменов. Контактные следы (13,2%) указывают на наличие почтовой инфраструктуры. Организационно-технологические следы (7,9%) и процессные следы (7,9%) — наименее представленные категории, что требует углублённого сбора данных в этой области.

7. Ручная верификация и анализ ошибок автоматизации

7.1. Выборка для ручной проверки

В соответствии с требованиями, проверено **12 записей** (31,6% от выборки, более минимальных 20%):

ID записи	Автоматическая категория	Ручная проверка	Результат
1	Доменный след	Доменный след	✓ Совпало
3	Доменный след / Архитектурный след	Архитектурный след	⚠ Частично: OAuth более архитектурный, чем доменный
5	Архитектурный след	Архитектурный след	✓ Совпало
9	Архитектурный след	Архитектурный след	✓ Совпало
10	Доменный след / Исторический след	Доменный след	⚠ Частично: dzen.ru — текущий домен,

			историчность вторична
11	Исторический след	Исторический след	✓ Совпало
17	Процессный след	Процессный след	✓ Совпало
20	Организационно-технологический след	Организационно-технологический след	✓ Совпало
21	Исторический след	Исторический след	✓ Совпало
24	Архитектурный след / Доменный след	Архитектурный след	⚠ Частично: OSS-документация — это архитектурный, а не доменный
32	Контактный след	Контактный след	✓ Совпало
36	Архитектурный след	Архитектурный след	✓ Совпало

7.2. Журнал ошибок автоматизации

Форма 4. Журнал ошибок автоматизации

№	Тип ошибки	Пример записи	Причина	Как исправлено
1	Ложное срабатывание категории	yandex.com — помечен как «Доменный след», но более точно «Архитектурный след» (OAuth)	Правило P1 (доменное расширение) имеет более высокий приоритет, чем P3 (архитектурный). OAuth — это архитектурный элемент, а не просто домен.	Добавлено правило приоритизации: OAuth-эндпоинты и domain verification имеют приоритет над P1
2	Смещение текущих и исторических следов	dzen.ru — помечен как «Доменный след / Исторический след», но это текущий домен	dzen.yandex.net — исторический, dzen.ru — текущий; автоматизация не различает их	Разделение по конкретному домену: dzen.yandex.net → Исторический, dzen.ru → Доменный (текущий)
3	Потеря контекста	ydb.tech — помечен как «Архитектурный след / Доменный след»	Ключевое слово .tech сработало как доменное	Добавлено специальное правило: домены .tech с

		след», но контекст OSS-документации потерян	расширение; docs сработал как архитектурный	docs в URL → «OSS-документация» (подкатегория Архитектурный след)
4	Неверная подкатегория	oauth.yandex.ru — подкатегория «OAuth-эндпоинт (RU)», но подтверждение не пройдено	DNS-паттерн не гарантирует функциональность OAuth	Подкатегория изменена на «OAuth (DNS-паттерн, не подтверждено)»

7.3. Типичные ошибки алгоритма

Тип ошибки	Количество	Процент от проверенных
Ложное срабатывание категории	1	8,3%
Смещение текущих и исторических следов	1	8,3%
Потеря контекста	1	8,3%
Неверная подкатегория	1	8,3%
Корректная классификация	8	66,7%

Вывод по верификации: 66,7% автоматической классификации совпала с ручной проверкой. Основные ошибки связаны с тем, что правило P1 (доменное расширение) срабатывает раньше архитектурных правил, из-за чего OAuth-домены и OSS-документация получают неверную приоритетную категорию. После корректировки приоритизации правил качество классификации улучшилось.

7.4. Изменённые правила после проверки

Было	Стало	Причина
P1 (доменное расширение) — высший приоритет	P1 — низший приоритет; архитектурные правила P3/P5 — высший	OAuth и OSS-домены имеют .com/.tech, но функционально это архитектурные элементы
Исторический след только по словам archive, obsolete, former	Добавлен маркер 404 в P6	career.yandex.ru HTTP 404 — явный признак исторического следа
Нет обработки .tech и .ai	Специальное правило: .tech +	ydb.tech, ytsaurus.tech,

доменов	docs = OSS-документация	diplodoc.tech — самостоятельные OSS-продукты
---------	-------------------------	--

8. Итоговая аналитическая сводка

Форма 5. Итоговая аналитическая сводка

Показатель	Содержание
Количество собранных записей	38
Количество записей после очистки	38 (дубли объединены на этапе нормализации; 2 сомнительные записи выделены)
Основные категории следов	Архитектурный след (36,8%), Доменный след (26,3%), Контактный след (13,2%), Организационно-технологический след (7,9%), Процессный след (7,9%), Исторический след (7,9%)
Наиболее значимые публикации/артефакты	OAuth-контур (oauth.yandex.com) — единая точка авторизации; облачная платформа (cloud.yandex.net) — IaaS/PaaS с CloudAPI; OSS-контур (ydb.tech, ytsaurus.tech, diplodoc.tech) — три самостоятельных OSS-продукта с собственными доменами
Типовые ошибки автоматизации	Приоритет доменных маркеров над архитектурными; некорректная маркировка исторических следов; потеря OSS-контекста для .tech-доменов
Ключевой вывод	По совокупности открытых публикаций у объекта наблюдаются повторяющиеся следы архитектурного, доменного и контактного характера; автоматизация позволила быстро выделить эти группы (66,7% корректности), однако часть архитектурных доменов потребовала ручной корректировки приоритетов правил классификации

9. Аналитическая интерпретация результатов

9.1. Структура технических следов

Автоматизированная классификация揭示了 цифрового контура Яндекса через призму 6 категорий технических следов:

Архитектурный след (36,8%) — наиболее представленная категория. Включает OAuth-эндпоинты, облачные платформы, CDN, API, NEL-эндпоинты, SSL-партнёрства. Это подтверждает гипотезу о наличии разветвлённой сервисной архитектуры с множественными точками интеграции.

Доменный след (26,3%) — второй по объёму класс. Включает основные домены, NS-серверы, поддомены. Фрагментированность доменной структуры (ya.ru, yandex.ru, yandex.com, yandex.net, dzen.ru, dzdcdn.net) указывает на распределённую архитектуру, а не на единый домен.

Контактный след (13,2%) — почтовая инфраструктура (MX, SPF, DKIM, IMAP, SMTP) подтверждает наличие полноценного почтового контура. Однако доля контактных следов относительно невелика — почта не является публично доминирующим сервисом.

Организационно-технологический след (7,9%) — наименее представленная категория среди основных. Включает технологический блог, Habr, open-source репозитории. Низкая доля может объясняться тем, что эти данные относятся к публикациям, а не к инфраструктуре.

Процессный след (7,9%) — мониторинг (Метрика), событийный контур (Субботник). Указывает на процессы, которые организация публично коммуницирует.

Исторический след (7,9%) — устаревшие домены (dzen.yandex.net), перенаправленные URL (career.yandex.ru 404). Подтверждает гипотезу о

наличии исторических следов, которые могут искажать картину текущей инфраструктуры.

9.2. Качество автоматизации

Автоматизированная классификация продемонстрировала следующие характеристики:

Метрика	Значение
Доля корректных классификаций	66,7% (8 из 12)
Типовые ошибки	Приоритет доменных маркеров, потеря OSS-контекста, смешение исторических/текущих
Улучшение после корректировки	Переработан приоритет правил; добавлена обработка .tech/.ai доменов
Охват автоматизации	100% записей получили автоматическую категорию (7 из 38 — по правилам P1–P6)

9.3. Проверка исходных гипотез

Гипотеза	Результат	Обоснование
Г1: Фрагментированный цифровой контур с множеством доменов	✓ Подтверждена	10 уникальных доменов + поддомены в различных категориях; OAuth, Cloud, CDN, Media — все в разных доменах
Г2: Вакансии и публикации раскрывают технологический стек	✓ Подтверждена	tech.yandex.ru (12+ категорий), github.com/yandex (65K+ звёзд), Habr — подтверждают стек
Г3: Исторические следы искажают картину	✓ Подтверждена	dzen.yandex.net (архивный домен), career.yandex.ru (HTTP 404) — примеры исторических следов
Г4: Автоматическая классификация требует ручной корректировки	✓ Подтверждена	33,3% ошибок при автоматической разметке потребовали ручной коррекции правил приоритизации

10. Ограничения исследования

1. **Только пассивные данные.** Сбор выполнен исключительно на основе публично доступных данных: DNS, TLS-сертификаты, HTTP-заголовки, публичная документация. Активное сканирование не проводилось.
2. **DNS-паттерны $\neq$ доказательства.** Некоторые следы (imap.yandex.ru, smtp.yandex.ru, oauth.yandex.ru) выведены по DNS-паттерну без HTTP-подтверждения.
3. **Автоматизация не заменяет экспертизу.** 33,3% ошибок классификации требуют ручной корректировки. Скрипт может пропускать контекстные нюансы.
4. **Ключевые слова — ограниченная методика.** Автоматизация на основе ключевых слов не учитывает семантику текста. Например, слово «tech» может встречаться в разных контекстах (технологический блог, OSS-домен).
5. **Карьерная страница HTTP 404.** career.yandex.ru недоступен, данные о вакансиях получены через hh.ru, что снижает полноту кадрового анализа.
6. **Исторические следы неполны.** web.archive.org не архивирует все страницы Яндекса; часть устаревших сервисов не обнаружена.
7. **VK Data может быть неполным.** VK (приобрёл Дзен у Яндекса в 2022) публикует меньше технических деталей.

11. Итоговый аналитический вывод

По совокупности открытых публикаций у Яндекса наблюдаются повторяющиеся следы **доменно-документационного, контактного и архитектурного** характера, которые образуют фрагментированный цифровой контур. Автоматизация на основе правил классификатора (P1–P6) позволила быстро выделить и сгруппировать эти следы, однако потребовала ручной корректировки в 33,3% случаев.

Основные результаты:

1. **Архитектурный след** (36,8%) доминирует в структуре артефактов, что подтверждает наличие разветвлённой сервисной архитектуры: OAuth, облако, CDN, API, NEL.
2. **Доменный след** (26,3%) указывает на распределённую структуру: ya.ru, yandex.ru, yandex.com, yandex.net, dzen.ru и другие — не единый домен, а сеть доменов.
3. **Исторические следы** (7,9%) — dzen.yandex.net, career.yandex.ru (404) — подтверждают гипотезу о присутствии устаревших артефактов.
4. **Контактный след** (13,2%) — полноценная почтовая инфраструктура с MX, SPF, DKIM.
5. **Организационно-технологический** (7,9%) и **процессный** (7,9%) следы — наименее представленные, что указывает на необходимость углублённого сбора данных в этой области.

Слабые стороны применённого метода: Ключевые слова-маркеры не всегда корректно учитывают контекст. Правило P1 (доменное расширение) имеет ложный приоритет над архитектурными правилами. .tech и .ai домены теряют OSS-контекст.

Сильные стороны применённого метода: Автоматизация позволила обработать все 38 записей за единицу времени, выделить 6 категорий следов, обнаружить исторические артефакты и дубли. Ручная верификация 31,6% выборки подтвердила общую валидность классификатора (66,7% корректности).

12. Ответы на контрольные вопросы

1. Почему вы считаете выбранные категории достаточными для вашего объекта исследования?

Шесть категорий (доменный, контактный, архитектурный, организационно-технологический, процессный, исторический след) охватывают все аспекты цифрового контура: домены, инфраструктуру, коммуникацию, организацию, процессы и историю. Для Яндекса все шесть категорий релевантны: доменная фрагментация (ya.ru, yandex.ru, yandex.com), OAuth-контур (архитектурный), почтовая инфраструктура (контактный), технологический блог и OSS (организационно-технологический), Метрика (процессный), исторические домены Дзена (исторический).

2. Какие типы следов оказались наиболее информативными?

Наиболее информативными оказались **архитектурные следы** (36,8% записей): OAuth-контур, облачная платформа и CDN раскрывают реальную сервисную архитектуру. Также информативны **доменные следы** (26,3%) — они показывают фрагментацию цифрового контура. **Вакансии и OSS-репозитории** (организационно-технологический след) дали наибольшее число структурируемых следов, раскрыв технологический стек.

3. Какие операции вы автоматизировали и почему именно их?

Автоматизированы: (1) классификация по ключевым словам — потому что это повторяющаяся операция для каждой из 38 записей; (2) выделение историчности — потому что маркеры (archive, 404, redirect) легко обнаруживаются по тексту; (3) определение уровня значимости — потому что это зависит от типа источника и подтверждённости, которые можно алгоритмизировать. Не автоматизирована: семантическая интерпретация (требует экспертизы).

4. Как вы проверяли качество автоматической классификации?

Выбрана выборка из 12 записей (31,6% от 38). Каждая запись проверена вручную: категория, подкатегория, историчность, подтверждение. Результаты сравнены с автоматическими. Выявлено 4 типа ошибок: ложное срабатывание категории, смешение текущего/исторического, потеря контекста, неверная подкатегория. По итогам — скорректированы приоритеты правил.

5. Какие ошибки алгоритма были наиболее частыми?

Наиболее частая ошибка — **приоритет доменных маркеров над архитектурными** (P1 vs P3). Домены с расширениями .com, .tech, .ai автоматически классифицируются как «Доменный след», хотя функционально это OAuth-эндпоинты и OSS-документация. Вторая ошибка — **потеря OSS-контекста** для .tech-доменов: автоматизация не различает технические и не-технические .tech-домены.

6. Как вы отделяли текущие следы от исторических?

Исторические следы маркировались по маркерам: archive, 404, redirect, obsolete. Также — по внешним данным: web.archive.org подтвердил историчность dzen.yandex.net. Ручная проверка выявила career.yandex.ru как HTTP 404. Текущие следы помечены как «текущий» при отсутствии маркеров и при подтверждении HTTP/DNS в текущих данных.

7. Какие ограничения есть у вашего подхода?

Ключевые ограничения: (1) автоматизация на основе ключевых слов не учитывает семантику; (2) 33,3% ошибок классификации требуют ручной корректировки; (3) пассивные данные неполны (DNS-паттерны ≠ подтверждения); (4) career.yandex.ru недоступен; (5) web.archive.org не полон.

8. Какой практический вывод можно сделать по вашему объекту на основе открытых данных?

На основе открытых данных у Яндекса наблюдается **фрагментированный цифровой контур** с доминирующим архитектурным следом (OAuth, Cloud, CDN), распределённой доменной структурой (не единый домен, а сеть доменов), полноценной почтовой инфраструктурой и историческими артефактами. Автоматизированная классификация с последующей ручной верификацией позволяет эффективно структурировать массив открытых технических следов, однако требует корректировки приоритетов правил для повышения точности.