

Мухаметшин Александр Ринатович

ББМО-01-25

Контрольная работа №1

1. Одним из важных аспектов машинного обучения является подготовка экспериментальных данных для последующего применения алгоритмов. Проводится эксперимент по оценке температуры технического устройства. По результатам замера данных в течение 8 часов получена следующая таблица, в которой присутствует ошибка.

9:00	10:00	11:00	12:00	13:00	14:00	15:00	16:00	17:00	18:00
20	22	22	25	23	323	24	25	24	24

Исправьте ошибку медианным значением. Медиана делит ранжированные данные (отсортированные по возрастанию или убыванию) на две равные части. Половина исходных данных меньше этой отметки, а половина – больше. В ответе укажите значение, которое должно быть внесено вместо ошибки.

Решение:

Массив без ошибки - {20, 22, 22, 25, 23, 24, 25, 24, 24}

Отсортированный - {20, 22, 22, 23, 24, 24, 24, 25, 25}

Медианное значение (5-й элемент) - 24

Ответ: 24

2. Для решения прикладных задач с применением методов машинного обучения зачастую необходимо производить нормировку. Нормировка данных состоит в преобразовании информации к новой форме представления. Такие преобразования позволяют исключить влияние на результаты анализа принятых единиц измерения.

Найдите нормированное значение возраста для третьей записи в таблице ниже, используя минимаксную нормировку:

$$x_i^{\text{норм}} = \frac{x_i - \min(x_i)}{\max(x_i) - \min(x_i)}$$

№	ФИО	Возраст
1	Евгений	30
2	Александр	70
3	Даниил	60

Решение:

$$(60-30)/(70-30)=30/40=0.75$$

Ответ: 0.75

3. Допустим, получена следующая множественная модель в стандартизированном виде:

$$Y = 0,9 \times X_1 + 0,1 \times X_2$$

какой из факторов оказывает наибольшее влияние на результирующую переменную:

- A. фактор X1
- B. фактор X2
- C. невозможно сравнивать влияние этих факторов
- D. оба фактора вносят одинаковый вклад

Решение: больше влияние $0,9 > 0,1$, значит фактор X1 оказывает наибольшее влияние.

Ответ: A. фактор X1.

4. Евклидово расстояние $d(A, B) = \sqrt{(x_A - x_B)^2 + (y_A - y_B)^2}$ является основной метрикой во многих алгоритмах искусственного интеллекта. Даны два объекта из датасета со следующим числовыми значениями признаков: A(1, 1) и B(4, 5). Определите евклидово расстояние между ними.

Решение:

$$d(a, b) = \sqrt{(1-4)^2 + (1-5)^2} = \sqrt{9+16} = 5$$

Ответ: 5

5. Даны векторы признаков для двух объектов и вектор весов:

$$X = \begin{pmatrix} 1 \\ 3 \\ 5 \end{pmatrix}; Y = \begin{pmatrix} 2 \\ 6 \\ 7 \end{pmatrix}; W = \begin{pmatrix} 0,5 \\ 0,5 \\ 1 \end{pmatrix}$$

Найдите взвешенное расстояние Евклида

$$P = \sqrt{\sum_{i=1}^N w_i (x_i - y_i)^2}.$$

Решение:

Подставляем значения для каждого i от 1 до 3:

$$i = 1: w_1 (x_1 - y_1)^2 = 0.5 * (1 - 2)^2 = 0.5 * 1 = 0.5$$

$$i = 2: w_2 (x_2 - y_2)^2 = 0.5 * (3 - 6)^2 = 0.5 * 9 = 4.5$$

$$i = 3: w_3 (x_3 - y_3)^2 = 1 * (5 - 7)^2 = 1 * 4 = 4$$

Теперь суммируем эти значения:

$$\text{sum} = 0.5 + 4.5 + 4 = 9$$

И извлекаем квадратный корень:

$$P = \sqrt{9} = 3$$

Ответ: 3

6. Дана таблица с данными по клиентам кредитной организации. Восстановите пропущенное число методом заполнения медианным значением (Медианное значение – центральный элемент в упорядоченном наборе чисел.

Если центрального элемента нет, то ищется среднее арифметическое его

Возраст, лет	Подтверждённый доход, тыс. руб.	Стоимость имущества, млн. руб.	Величина взятого кредита, тыс. руб.
31	200	20	400
27	100	10	100
44	250	???	325
соседей). 41	150	10	175

Решение:

Массив без ошибки - {20, 10, 10}

Отсортированный - {10, 10, 20}

Медианное значение (2-й элемент) - 10

Ответ: 10

7. Для решения прикладных задач с применением методов машинного обучения необходимо производить нормировку.

Найдите нормированное значение заработной платы для первой записи

$$x_i^{\text{норм}} = \frac{x_i - \min(x_i)}{\max(x_i) - \min(x_i)}$$

№	ФИО	Заработная плата
1	Евгений	60000
2	Александр	120000
3	Даниил	20000

в таблице ниже, используя минимаксную нормировку:

Решение:

$(60000 - 20000) / (120000 - 20000) = 40000 / 100000 = 0,4$

Ответ: 0,4

8. Дан датасет «Сотрудники»:

№	ФИО	Возраст	Пол	Стаж работы	Доход, тыс. рублей
1	Антонова Антонина	30	ж	10	50
2	Борисов Борис	26	м	6	26
3	Владимиров Владимир	40	м	20	80
4	Григорьев Григорий	20	м	0	20

Укажите, какое значение будет в столбце «Доход» у Борисова Бориса после проведения процедуры нормирования данных?

Для нормировки используется формула:

$$x_i^{\text{норм}} = \frac{x_i - \min(x_i)}{\max(x_i) - \min(x_i)}$$

В ответ запишите результат нормировки для второй записи в столбце «Доход» (без пробелов, разделитель разрядов запятой).

Решение:

$(26 - 20) / (80 - 20) = 6 / 60 = 0,1$

Ответ: 0,1

9. В результате применения регрессионной модели к исходным данным (x, y) были получены следующие предсказанные значения $y_{расч}$ на тех же данных:

x	y	$y_{расч}$
1	2	3
3	3	4
5	6	5
7	6	3

Оцените качество модели, используя для этого метрику MSE (Mean Squared Error):

$$\frac{1}{n} \sum_{i=1}^n (y_i - w^T x_i)^2$$

В ответ запишите получившееся число.

Решение:

$i = 1$: $(y_1 - y_{1расч}) = (2 - 3) = -1$. Квадрат ошибки: $(-1)^2 = 1$

$i = 2$: $(y_2 - y_{2расч}) = (3 - 4) = -1$. Квадрат ошибки: $(-1)^2 = 1$

$i = 3$: $(y_3 - y_{3расч}) = (6 - 5) = 1$. Квадрат ошибки: $(1)^2 = 1$

$i = 4$: $(y_4 - y_{4расч}) = (6 - 3) = 3$. Квадрат ошибки: $(3)^2 = 9$

Сумма квадратов ошибок $\text{sum} = 1 + 1 + 1 + 9 = 12$

$\text{MSE} = 12/4 = 3$

Ответ: 3

10. В результате применения регрессионной модели к исходным данным (x, y) были получены следующие предсказанные значения $y_{расч}$ на тех же данных:

x	y	$y_{расч}$
1	9	3
4	3	2
6	6	8
8	9	6

Оцените качество модели, используя для этого метрику MAE (Mean Absolute Error):

$$\frac{1}{n} \sum_{i=1}^n |y_i - w^T x_i|$$

В ответ запишите получившееся число.

Решение:

$|9 - 3| = 6$

$|3 - 2| = 1$

$|6 - 8| = 2$

$$|9 - 6| = 3$$

$$MAE = (6 + 1 + 2 + 3)/4 = 12/4 = 3$$

Ответ: 3

11. В результате применения регрессионной модели к исходным данным (x, y) были получены следующие предсказанные значения $y_{расч}$ на тех же данных:

x	y	$y_{расч}$
1	2	3
3	3	4
5	6	5
7	6	3

$$\frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - w^T x_i}{y_i} \right|$$

Оцените качество модели, используя для этого метрику MAPE (Mean absolute percentage error):

В ответ запишите получившееся число.

Решение:

$$|2-3|/2 = 1/2$$

$$|3-4|/3 = 1/3$$

$$|6-5|/6 = 1/6$$

$$|6-3|/6 = 1/2$$

$$MAPE = (0.5 + 1/3 + 1/6 + 0.5)/4 = (1 + 3/6)/4 = 1.5/4 = 0.375$$

Ответ: 0.375

12. В результате применения регрессионной модели к исходным данным (x, y) были получены следующие предсказанные значения $y_{расч}$ на тех же данных:

x	y	$y_{расч}$
1	9	3
4	3	2
6	6	8
8	9	6

$$\frac{\sum_{i=1}^n |y_i - w^T x_i|}{\frac{n}{n-1} \sum_{i=2}^n |y_i - y_{i-1}|}$$

Оцените качество модели, используя для этого метрику MASE (Mean absolute scaled error):

В ответ запишите получившееся число.

Решение:

Числитель: $|9-3| + |3-2| + |6-8| + |9-6| = 6 + 1 + 2 + 3 = 12$

Знаменатель: $|3-9| + |6-3| + |9-6| = 6 + 3 + 3 = 12$

$MASE = 12/(4/3 * 12) = 12/16 = 0.75$

Ответ: 0.75

13. В результате применения регрессионной модели к исходным данным (x,y) были получены следующие предсказанные значения $y_{расч}$ на тех же данных:

x	y	$y_{расч}$
1	2	3
3	3	4
5	6	5
7	6	3

Оцените качество модели, используя для этого метрику R^2 (коэффициент детерминации):

$$1 - \frac{\frac{1}{n} \sum_{i=1}^n (y_i - w^T x_i)^2}{\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2}$$

В ответ запишите получившееся число.

Решение:

Числитель: $(2-3)^2 + (3-4)^2 + (6-5)^2 + (6-3)^2 = (-1)^2 + (-1)^2 + 1^2 + 3^2 = 1 + 1 + 1 + 9 = 12$

Среднее y : $(2+3+6+6)/4 = 17/4 = 4.25$

Знаменатель: $(2-4.25)^2 + (3-4.25)^2 + (6-4.25)^2 + (6-4.25)^2 = (-2.25)^2 + (-1.25)^2 + (1.75)^2 + (1.75)^2 = 5.0625 + 1.5625 + 3.0625 + 3.0625 = 12.75$

$R^2 = 1 - 12/12.75 = 1 - 48/51 = 1 - 16/17 = 1/17 = 0.0588$

Ответ: 0.0588

14. Для набора исходных данных (x,y) построить модель линейной регрессии:

x	y
1	-1
2	1
3	2
4	4
5	6

Оцените качество модели, используя для этого метрику MSE (Mean Squared Error):

$$\frac{1}{n} \sum_{i=1}^n (y_i - w^T x_i)^2$$

В ответ запишите получившиеся модель и число.

Решение:

$$0^2 + (0.3)^2 + (-0.4)^2 + (-0.1)^2 + (0.2)^2 = 0 + 0.09 + 0.16 + 0.01 + 0.04 = 0.3$$

$$\text{MSE} = 0.3/5 = 0.06$$

Ответ: 0.06

15. Для набора исходных данных (x, y) построить модель линейной регрессии:

x	y
1	-1
2	1
3	2
4	4
5	6

Оцените качество модели, используя для этого метрику **MAE** (Mean absolute error):

$$\frac{1}{n} \sum_{i=1}^n |y_i - w^T x_i|$$

В ответ запишите получившиеся модель и число.

Решение:

$$|0| + |0.3| + |-0.4| + |-0.1| + |0.2| = 0 + 0.3 + 0.4 + 0.1 + 0.2 = 1$$

$$\text{MAE} = 1/5 = 0.2$$

Ответ: 0.2

16. Для набора исходных данных (x, y) построить модель линейной регрессии:

x	y
1	-1
2	1
3	2
4	4
5	6

$$\frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - w^T x_i}{y_i} \right|$$

Оцените качество модели, используя для этого метрику **MAPE** (Mean absolute percentage error):

В ответ запишите получившиеся модель и число.

Решение:

$$|0|/-1 = 0$$

$$|0.3|/1 = 0.3$$

$$|-0.4|/2 = 0.4/2 = 0.2$$

$$|-0.1|/4 = 0.1/4 = 0.025$$

$$|0.2|/6 = 0.2/6 = 1/30$$

$$\text{MAPE} = 0 + 0.3 + 0.2 + 0.025 + (1/30)/5 = 0.525 + (1/30)/5 = 67/120/5 = 67/600 = 0.11166..$$

Ответ: 0.11166

17. Для набора исходных данных (x, y) построить модель линейной регрессии:

x	y
1	-1
2	1
3	2
4	4
5	6

$$\frac{\sum_{i=1}^n |y_i - w^T x_i|}{\frac{n}{n-1} \sum_{i=2}^n |y_i - y_{i-1}|}$$

Оцените качество модели, используя для этого метрику **MASE** (Mean absolute scaled error):

В ответ запишите получившиеся модель и число.

Решение:

Числитель: 1.0 (из п 15)

Знаменатель:

$$\text{Сумма наивных ошибок: } |1 - (-1)| + |2 - 1| + |4 - 2| + |6 - 4| = 2 + 1 + 2 + 2 = 7$$

Коэффициент: 5/4

$$\text{Знаменатель} = 5/4 * 7 = 35/4 = 8.75$$

$$\text{MASE} = 1.0/8.75 = 1/35/4 = 4/35 = 0.11428...$$

Ответ: 0.11428

18. Дана обучающая выборка из 100 объектов, описывающая опрос респондентов по их намерению купить новый товар. В результате опроса – 70 клиентов ответили, что купят товар, 30 ответили, что не купят товар. На данной выборке построена и обучена модель классификации, получен результат: из 70 клиентов, которые купят товар, модель верно классифицировала 65 (True Positive, TP), а 5 ошибочно отнесла к классу, кто не купит (False Negative, FN); из 30 клиентов, кто ответил, что не купит товар модель верно

классифицировала 25 (True Negative, TN), а 5 ошибочно отнесла к классу купит (False Positive, FP).

В результате машинного обучения модели получена матрица ошибок

True Positive (TP) 65	False Positive (FP) 5
False Negative (FN) 5	True Negative (TN) 25

Вычислите точность (Accuracy) обученного алгоритма.

В ответ запишите число без пробелов, разделитель разрядов запятой.

Решение:

$$(65 + 25) / (65 + 25 + 5 + 5) = 90 / 100 = 0.9$$

Ответ: 0.9

19. Дана таблица с данными по клиентам кредитной организации:

	Возраст, лет	Подтверждённый доход, тыс. руб.	Величина взятого кредита, тыс. руб.	Кредит возвращён, да / нет
	40	200	175	да
	30	150	250	да
	30	150	400	нет
	50	100	100	нет
	40	150	175	???

Для человека из таблицы выше, у которого неизвестна кредитная история, необходимо определить, вернёт ли он кредит.

Для решения задачи используйте метод К-ближайших соседей, где K=1.

$$\rho(x, y) = \sum_{i=1}^n |x_i - y_i|$$

Для нахождения расстояния между объектами используйте следующую метрику:

В ответе запишите либо да, либо нет.

Решение:

Рассчитанные расстояния

Объект	Расстояние	Класс
№1	0.25	да
№2	0.55	да
№3	0.8125	нет
№4	0.9619	нет

Минимальное расстояние $d=0.25$ соответствует Объекту №1.

Поскольку $K=1$, классифицируемый объект (№5) принимает класс своего единственного ближайшего соседа. Ближайший сосед (Объект №1)

имеет класс "да".

Ответ: да

20. Для решения прикладных задач с применением методов машинного обучения зачастую необходимо производить нормировку. Нормировка данных состоит в преобразовании информации к новой форме представления. Такие преобразования позволяют исключить влияние на результаты анализа принятых единиц измерения.

Найдите нормированное значение заработной платы для первой записи

$$x_i^{\text{норм}} = \frac{x_i - \min(x_i)}{\max(x_i) - \min(x_i)}$$

в таблице ниже, используя минимаксную нормировку:

№	ФИО	Зарботная плата
1	Евгений	60000
2	Александр	120000
3	Даниил	20000

В поле введите результат нормировки для первой записи (без пробелов, разделитель разрядов запятой).

Решение:

$$(60000 - 20000) / (120000 - 20000) = 40000 / 100000 = 0.4$$

Ответ: 0.4

21. В результате применения регрессионной модели к исходным данным (x, y) были получены следующие предсказанные значения $y_{\text{расч}}$ на тех же данных

x	y	$y_{\text{расч}}$
2	1	3
3	2	2
4	7	5
5	8	8

Оцените качество модели, используя для этого метрику **MSE (Mean square error)**:

$$\frac{1}{n} \sum_{i=1}^n (y_i - w^T x_i)^2$$

В ответ запишите получившееся число

Решение:

x	y	$y^{\wedge}$ (Предсказано)	Разнос ть ($y - y^{\wedge}$)	Квадр ат разности ($y - y^{\wedge}$) ²
2	1	3	-2	4
3	2	2	0	0
4	7	5	2	4
5	8	8	0	0
Сум ма				8

$$MSE = 1/4 * (4 + 0 + 4 + 0) = 8/4 = 2$$

Ответ: 2

22. Для набора данных, постройте байесовский спам-фильтр.
Расчетные формулы представлены ниже.

Определить является ли входящее сообщение (письмо) спамом/ не спамом

Количество писем, содержащих слова

Встречаемость слова в письме	Все письма	Все спам письма	Все не спам письма
Слово 1 (Мама)	15	3	12
Слово 2 (Папа)	15	3	12
Слово 3 (Работа)	30	20	10
Слово 4 (Уважаемый)	50	30	20
Слово 5 (Подпишись)	25	20	5
...	...	...	...
Слово N (Вклад)	20	5	15
Всего писем	100	35	65

Частота встречаемости писем со словами

Частота встречи слова в письме	Все спам письма	Все не спам письма
Слово 1 (Мама)	3/35 = 9 %	12/65 = 18 %
Слово 2 (Папа)	3/35 = 9 %	12/65 = 18 %
Слово 3 (Работа)	20/35 = 57 %	10/65 = 15 %
Слово 4 (Уважаемый)	30/35 = 86 %	20/65 = 31 %
Слово 5 (Подпишись)	20/35 = 57 %	5/65 = 8 %
...	...	...
Слово N (Вклад)	5/35 = 14 %	15/65 = 15 %

Частота встречаемости писем

Все письма	Количество	Доля
Спам	35	35 %
Не спам	65	65 %
Всего	100	100 %

Для каждого слова (W) входящего сообщения (письма) считаем условную вероятность (Pr) того, что письмо является спамом (S), при условии встретить в нем слово (W)

$$\Pr(S | W) = \frac{\Pr(W | S) \cdot \Pr(S)}{\Pr(W)} = \frac{\Pr(W | S) \cdot \Pr(S)}{\Pr(W | S) \cdot \Pr(S) + \Pr(W | H) \cdot \Pr(H)}$$

$\Pr(S W)$	условная вероятность того, что письмо – спам, при условии что слово W находится в нем
$\Pr(S)$	полная вероятность того, что письмо – спам
$\Pr(W S)$	условная вероятность того, что слово W встречается в письме, при условии того, что оно спам
$\Pr(H)$	полная вероятность того, что письмо – не спам
$\Pr(W H)$	условная вероятность того, что слово W встречается в письме, при условии того, что письмо не спам

Все слова в сообщении	$\Pr(W S)$	$\Pr(S)$	$\Pr(W H)$	$\Pr(H)$	$\Pr(S W)$
Слово 1 (Мама)	9%	35%	18%	65%	$9\% \cdot 35\% / (9\% \cdot 35\% + 18\% \cdot 65\%) = 20\%$
Слово 2 (Уважаемый)	86%	35%	31%	65%	$86\% \cdot 35\% / (86\% \cdot 35\% + 31\% \cdot 65\%) = 60\%$
...	...	...	...	...	...
Слово N (Подпишись)	57%	35%	8%	65%	$57\% \cdot 35\% / (57\% \cdot 35\% + 8\% \cdot 65\%) = 80\%$

Для что все письмо, содержащее слова $W_1, W_2, \dots, W_N$ является спамом

$$p = \frac{p_1 p_2 \cdots p_N}{p_1 p_2 \cdots p_N + (1 - p_1)(1 - p_2) \cdots (1 - p_N)}$$

$p = \Pr(S | W_1, W_2, \dots, W_N)$ — вероятность, что сообщение, содержащее слова $W_1, W_2, \dots, W_N$ — спам;
 p_1 — условная вероятность $\Pr(S | W_1)$ того, что сообщение — спам, при условии, что оно содержит первое слово
 p_2 — условная вероятность $\Pr(S | W_2)$ того, что сообщение — спам, при условии, что оно содержит второе слово
 p_N — условная вероятность $\Pr(S | W_N)$ того, что сообщение — спам, при условии, что оно содержит N-е слово

Определите является ли письмо спамом или нет. В качестве порогового числа использовать значение 0,55 (55%). В ответе укажите численное значение рассчитанного показателя и вывод: спам или не спам.

Ответ: спам